

WGP-STANDPUNKT

# KI IN DER PRODUKTION

KÜNSTLICHE INTELLIGENZ ERSCHLIESSEN FÜR UNTERNEHMEN



## »WGP-Standpunkt KI in der Produktion«

Die Wissenschaftliche Gesellschaft für Produktionstechnik e.V. ist ein Zusammenschluss führender deutscher Professorinnen und Professoren der Produktionswissenschaft. Sie vertritt die Belange von Forschung und Lehre gegenüber Politik, Wirtschaft und Öffentlichkeit. Die WGP vereinigt 65 Professorinnen und Professoren aus rund 40 Universitäts- und Fraunhofer-Instituten und steht für ca. 2.000 Wissenschaftlerinnen und Wissenschaftler der Produktionstechnik. Die Mitglieder genießen sowohl in der deutschen Wissenschaftslandschaft als auch international eine hohe Reputation und sind weltweit vernetzt.

Die Labore der Mitglieder sind auf einem hohen technischen Stand und erlauben den WGP-Professoren, in ihren jeweiligen Themenfeldern sowohl Forschung als auch praxisorientierte Lehre zu betreiben.

Die WGP hat sich zum Ziel gesetzt, die Bedeutung der Produktion und der Produktionswissenschaft für die Gesellschaft und für den Standort Deutschland aufzuzeigen. Sie bezieht Stellung zu gesellschaftlich relevanten Themen von Industrie 4.0 über Energieeffizienz bis hin zu 3D-Druck.

## Impressum

### Herausgeber

WGP Wissenschaftliche Gesellschaft für Produktionstechnik e.V.  
vertreten durch den Präsidenten Berend Denkena, Leibniz Universität  
Hannover

### Verantwortliche Autoren

Jörg Krüger, Technische Universität Berlin (*redaktionelle Leitung*)  
Jürgen Fleischer, Karlsruher Institut für Technologie  
Jörg Franke, Friedrich-Alexander-Universität Erlangen-Nürnberg  
Peter Groche, Technische Universität Darmstadt

## Inhalt

<b>1</b>	<b>Management Summary .....</b>	<b>3</b>
<b>2</b>	<b>Warum dieser WGP-Standpunkt? .....</b>	<b>4</b>
<b>3</b>	<b>Begriffsbestimmungen.....</b>	<b>5</b>
<b>4</b>	<b>Wertschöpfungspotenziale von KI in der Produktion .....</b>	<b>7</b>
	4.1 Daten .....	9
	4.2 Anwendung .....	9
	4.3 Beurteilung .....	11
	4.4 Training und Feedback.....	12
<b>5</b>	<b>Datengetriebene vs. prozessgetriebene Anwendung von KI/ML .....</b>	<b>12</b>
<b>6</b>	<b>Anwendungsbeispiele aus der produktionstechnischen Forschung der WGP .....</b>	<b>14</b>
	6.1 CNC-Maschinen und -bearbeitung.....	17
	6.2 Handhabung, Montage und Robotik.....	19
	6.3 Materialfluss und Logistik.....	20
<b>7</b>	<b>Handlungsempfehlungen .....</b>	<b>21</b>
	7.1 Analyse der unternehmenseigenen Zielsetzung .....	21
	7.2 Aufbau von Expertise.....	21
	7.3 An einfachen Beispielen Erfahrungen sammeln .....	21
	7.4 Produktionstechnisches Prozesswissen für ML identifizieren und nutzen.....	21
	7.5 Daten systematisch gewinnen .....	22
	7.6 Know-how gezielt zusammenführen .....	22
	7.7 Potenziale vorausschauend bewerten .....	23
	7.8 KI-Methoden gezielt zur Assistenz einsetzen .....	23
<b>8</b>	<b>Referenzen .....</b>	<b>24</b>



# 1 Management Summary

KI-Verfahren bergen erhebliches Potenzial, um die Leistungen in der Produktion deutlich zu steigern und damit die Wettbewerbsfähigkeit in Deutschland zu stärken. Hierfür ist es jedoch entscheidend, KI-Kompetenz mit produktionstechnischer Kompetenz zu verbinden.

## Was ist neu?

Um die internationale Wettbewerbsfähigkeit einer produktionstechnischen Nutzung von KI in Deutschland zu sichern, bedarf es eines **schnellen und systematischen Transfers von der Forschung in die Anwendung**. Hierzu fehlte jedoch bisher ein umfassendes, **methodisches Vorgehensmodell**.

Bisher ist der produktionstechnische Einsatz von KI überwiegend datengetrieben, nutzt also Daten produktionstechnischer Prozesse als Basis für intelligente Analysen und Funktionen, ohne jedoch gezielt und systematisch das Wissen über die Prozesse selbst zu integrieren.

Der vorliegende Standpunkt verfolgt die Perspektive, dass ein **prozessgetriebenes anstelle eines datengetriebenen Vorgehensmodells** die effizienteste Grundlage für eine systematische Integration von KI-Kompetenzen mit produktionstechnischem Wissen darstellt. **Ausgewählte Beispiele** aus den inzwischen umfangreichen Forschungsarbeiten der WPG-Institute zur Integration von KI und Produktionstechnik belegen das große Innovationspotenzial dieser methodischen Sichtweise. Die Beispiele adressieren ein breites Spektrum produktionstechnischer Anwendungen von Werkzeugmaschinen und CNC-Bearbeitung über Handhabung, Montage und Robotik bis hin zu Materialfluss und Logistik. Hier verbindet sich Expertenwissen aus diesen Domänen mit dem Know-how zur Anwendung leistungsfähiger maschineller Lernverfahren.

## Was bedeutet dies für produzierende Unternehmen?

Mit dem hier verfolgten prozessorientierten Ansatz gibt der Standpunkt produzierenden Unternehmen eine Orientierung, wie sie ihr häufig wettbewerbsentscheidendes domänenspezifisches Prozess- und Anlagenwissen im Unternehmen mit neuen Fähigkeiten aus dem Bereich der KI zusammenzuführen können. Hiermit wird eine methodische Grundlage geschaffen, um automatisierte maschinelle Lernverfahren mit dem über viele Jahre entstandenen wertvollen Erfahrungswissen der Mitarbeiter in der Produktion zu verbinden. Der Standpunkt gibt eine Übersicht über unterschiedliche Modellansätze, die hierbei integriert werden.

Entscheidend für die Sicherung der Wettbewerbsfähigkeit in der Produktion durch systematische Integration von KI ist es, **neue Wertschöpfungspotenziale frühzeitig zu erschließen**. Dazu gehört, die Wertschöpfungsanteile richtig zu bewerten, die durch neue

KI-Methoden, entsprechende Softwarewerkzeuge, deren systematische Anwendung sowie die dazu benötigten Daten entstehen. Nicht zuletzt birgt auch das Wissen der Mitarbeiter um die Zuverlässigkeit von KI-Technologien in der Produktion neue Wertschöpfungspotenziale. In diesem Standpunktpapier geht es im Kern darum, diese **einzelnen Faktoren unter dem Gesichtspunkt zukünftiger Wertschöpfungspotenziale zu bewerten**.

## Was ist zu tun?

Aus der Erfahrung der WPG-Institute in der Nutzung von KI in unterschiedlichen Anwendungsdomänen leitet der Standpunkt acht **Handlungsempfehlungen** ab, die es Unternehmen ermöglichen, Anwendungspotenziale systematischer und damit schneller als bisher zu identifizieren und zu erschließen.

Dies betrifft zunächst die erforderliche grundlegende Analyse, **welche Form von „Intelligenz“** einer Maschine, einer Anlage oder eines Roboters angestrebt wird, wie dieser Lernprozess kontrolliert werden kann und **welche Daten als Grundlage für diesen Lernprozess dienen sollen**.

Die **systematische Erhebung von Daten** ist die wichtigste Grundlage zum Anlernen von KI-Methoden. Hierzu sind **Datenquellen zu identifizieren** sowie die Beziehungen zwischen den Daten auf Grundlage vorhandener Prozesskenntnis zu analysieren. Darüber hinaus zeigten sich interessante Potenziale zum Einsatz von **Simulationsverfahren** zur Erweiterung der Datenbasis.

Ein weiteres Handlungsfeld für Unternehmen betrifft die **Verbindung von Mensch und KI**. Bisher kaum beachtet sind die Potenziale, die nach wie vor überlegenen kognitiven und sensomotorischen Fähigkeiten des Menschen mit **KI in der Produktion als Assistenz** zu unterstützen. Der Standpunkt erläutert dies an einem Beispiel.

Für den grundlegenden **Aufbau von Expertise** im Bereich der KI empfiehlt der Standpunkt **Kooperationen mit erfahrenen Dienstleistern oder Forschungseinrichtungen**, um erste Vorhaben gemeinsam durchzuführen, um die nötige Kompetenz aufzubauen.

Für die **Wettbewerbsfähigkeit des Unternehmens** wird es entscheidend sein, das **produktionstechnische Wissen** für die Verbindung mit maschinellen Lernverfahren gezielt zu identifizieren und zu nutzen. Zur Absicherung der zukünftigen Wettbewerbsfähigkeit ist es darüber hinaus geboten, **prospektive Szenarioanalysen** durchzuführen, um frühzeitig **neue Wertschöpfungsmodelle** zu identifizieren.



## 2 Warum dieser WGP-Standpunkt?

Das Thema Künstliche Intelligenz (KI) ist im Jahr 2018 stark in den Fokus der öffentlichen Wahrnehmung gerückt. Medien berichten seit-her täglich über neue Fortschritte auf diesem Gebiet. Länder schätzen die wirtschaftspolitische Bedeutung inzwischen so hoch ein, dass sie die Entwicklung nationaler Kompetenzen zur strategischen Aufgabe erklären.

Die Institute der WGP (Wissenschaftliche Gesellschaft für Produktions-technik) erforschen bereits seit über 30 Jahren Anwendungen künstli-cher Intelligenz in der Produktion [1], [2]. Allerdings waren viele der KI-Methoden bisher noch nicht so leistungsfähig und ausgereift, dass auch deren wirtschaftlicher Einsatz in der betrieblichen Praxis möglich war. Inzwischen ist jedoch die Informatik in der Lage, Algorithmen und Rechenleistung bereitzustellen, auf deren Grundlage die Forschung und Entwicklung der WGP-Institute systematisch eine Vielzahl konkreter produktionstechnischer Anwendungen aufzeigt.

### Systematische Erschließung neuer Wertschöpfungspotenziale

Mit ihren Standpunkten „Industrie 4.0“ [3] und „Industriearbeitsplatz 2025“ [4] hat die WGP bereits KI-bezogene Fragestellungen adres-siert, wie zum Beispiel autonome Systeme in der Produktion und deren Einfluss auf die Arbeitswelt. Der vorliegende Standpunkt hat zum Ziel, **neue Wertschöpfungspotenziale für die Produktionstechnik** in Deutschland zu erschließen. Hierzu greift die WGP auf ihre einzig-artige domänenspezifische Kompetenz in der Produktionstechnik zurück und verknüpft sie mit aktuellen technologischen Entwicklungen der KI. Darüber hinaus erhalten Unternehmen der Produktionstechnik **Hand-lungsempfehlungen**, mit deren Hilfe sie die eigenen produktions-technischen Kompetenzen und Daten nutzen können, um mittels KI neue Potenziale systematisch zu erschließen.

In den Instituten der WGP werden derzeit eine Vielzahl unterschied-licher Forschungs- und Entwicklungsarbeiten durchgeführt, in denen KI-Technologien zur Verbesserung produktionstechnischer Prozes-se, Maschinen und Anlagen eingesetzt werden. Der Standpunkt zeigt anhand dieser Beispiele auf, welche neuen Wertschöpfungspotenziale bereits auf Basis der spezifischen Kompetenzen im Unternehmen erschlossen werden können und **welche zusätzlichen Kompetenzen und Strukturen aufgebaut** werden sollten.

Eine Besonderheit des Erfahrungswissens der WGP-Institute ist, dass deren Forschungs- und Entwicklungsarbeiten auf dem Gebiet KI/ maschinelles Lernen (ML) **typischerweise prozessorientiert** sind. Das heißt, bei diesem „Pull“-Ansatz resultiert der Ursprung für die Anwendung von KI/ML-Verfahren aus einem konkreten Bedarf, Pro-duktionsprozesse zu optimieren. Dies hat wesentliche Konsequenzen

für die Frage, auf welchen Daten gezielt maschinelle Lernverfahren angewendet werden und wie diese Daten gewonnen werden können. Im Unterschied hierzu sind **viele der bisherigen Anwendungen** maschineller Lernverfahren in der Produktion **datengetrieben**, also allein abhängig davon, welche Daten verfügbar sind („Push“-Ansatz). Gerade im Zusammenhang mit der „Sensorisierung“ von Maschinen und Anlagen im Zuge von Industrie 4.0 werden in Unternehmen zuneh-mend Daten gesammelt, auf denen Lernverfahren im Sinne der sogea-nannten „intelligenten Datenanalyse“ angewendet werden. Gegenüber dem informationstechnisch datengetriebenen „Push“-Ansatz bietet der produktionstechnisch prozessorientierte „Pull“-Ansatz jedoch wesent-lich mehr Potenzial, Domänenwissen aus der Produktion zu nutzen. Ein Ziel dieses Standpunktes ist auch, auf dieses Potenzial systematisch prozessorientierter Vorgehensweisen hinzuweisen.

Die Bundesregierung hat im November 2018 ihre Strategie Künstli-che Intelligenz veröffentlicht, in der sie die Entwicklung von Innova-tionen, Rahmenbedingungen für Unternehmensgründungen, Struktur-wandel der Arbeitswelt, Aus- und Weiterbildung und den Umgang mit Daten thematisiert [5]. Die WGP will mit dieser Publikation einen weiteren Beitrag leisten, **die Wettbewerbsfähigkeit produzie-render Unternehmen in Deutschland** zu stärken. Dabei spielt die Geschwindigkeit, mit der die Potenziale in der Industrie erschlossen und nachhaltig umgesetzt werden, eine entscheidende Rolle. Doch obwohl seit über 50 Jahren intensiv auf dem Gebiet maschineller Lernverfahren, wie beispielsweise der künstlichen neuronalen Netze (KNN), geforscht wird, gibt es noch vergleichsweise wenige Anwendungen in der Produk-tion. Es fehlt vor allem an einer systematischen Vorgehensweise, um zu prüfen, welche Aufgabengebiete in der Produktion sich für KI- bzw. ML-Anwendungen eignen. Umgekehrt fehlt es aber auch an Methoden, mit denen sich die verschiedenen ML-Verfahren auf ihre Eignung für eben diese Aufgabengebiete analysieren lassen.

Nicht zuletzt fehlen auch Betrachtungen bezüglich der **Wirtschaft-lichkeit neuer KI/ML-basierter Anwendungen**. Eine besondere Rolle spielt hierbei die Kompetenz der Unternehmen, die Zuverlässig-keit und Robustheit maschinell lernender Verfahren bewerten zu kön-nen. Die WGP schließt die genannten Lücken und formuliert in diesem Standpunkt Handlungsempfehlungen für die schnelle und erfolgreiche Erschließung von Wertschöpfungspotenzialen von KI/ML für produzierende Unternehmen. Sie gibt darüber hinaus **Handlungsempfehlungen für Wissenschaftler und Politiker**, damit diese gezielt wesentli-che, noch offene methodische Fragen zur systematischen industriellen Umsetzung klären können.

### 3 Begriffsbestimmungen

Mit KI werden verschiedene Fähigkeiten verbunden, bei denen Formen der menschlichen Intelligenz auf Computern abgebildet werden [5]. Beispiele hierfür sind das natürliche Sprachverstehen auf Computern sowie das maschinelle Sehen. Eine allgemeingültige konsistente Definition von KI gibt es jedoch nicht. Die Technologien, mit denen diese Fähigkeiten auf Computern abgebildet werden, sind häufig dem Gebiet des ML zuzuordnen, das einen Teilbereich der KI darstellt.

#### Schwache KI im Fokus

Der Begriff der KI wird häufig unterschiedlich verstanden, was eine weitere Spezifikation erfordert. In dem im November 2018 erschienenen Strategiepapier der Bundesregierung wird deswegen zwischen „schwacher“ und „starker“ KI unterschieden [5]. Starke KI bezeichnet demgemäß Systeme, die die „gleichen intellektuellen Fähigkeiten wie der Mensch haben oder ihn darin sogar übertreffen können“. Schwache KI fokussiert dagegen „auf die Lösung konkreter Anwendungsprobleme auf Basis der Methoden der Mathematik und Informatik, wobei die Systeme zur Selbstoptimierung fähig sind“. Im Sinne dieser **anwendungsorientierten und auf Selbstoptimierung von Systemen ausgerichteten** „schwachen“ KI wird der Begriff KI auch in diesem Standpunkt verwendet.

Eine weitere begriffliche Vermischung entsteht durch die Überlappung von Technologien des ML und der **intelligenten Datenanalyse (Data Mining)**. Letztere hat insbesondere durch die Einführung von Industrie 4.0 deutlich an Bedeutung gewonnen. Grund ist die stark gewachsene Zahl an Daten von Maschinen, Anlagen und Prozessen. Aber auch die Spezifikation des Cross Industry Standard Process Modells (CRISP-DM) [6] auch für die Datenanalyse in der Produktion hat dazu beigetragen. Der VDMA stellt die Relation in seinem 2018 erschienen „Quick Guide Machine Learning im Maschinen- und Anlagenbau“ [7] wie folgt dar: „Die Statistik definiert, was passiert ist; das Data Mining erklärt, warum etwas geschehen ist; das ML bestimmt, was passieren wird und gibt vor, wie bestimmte Situationen optimiert oder vermieden werden können.“

Es sind insbesondere die Fortschritte auf dem Gebiet des ML, die in den vergangenen Jahren neue Potenziale für Anwendungen von KI in der Produktion aufzeigten. Die damit verbundenen Begriffe sollen daher an dieser Stelle eingehender betrachtet werden. ML bezeichnet Verfahren, die sich anhand von Daten ein möglichst optimales Verhalten antrainieren können, ohne dass jeder Einzelfall explizit programmiert werden muss [8]. Hierbei werden verschiedene Prinzipien des Lernens unterschieden: das überwachte Lernen, das unüberwachte Lernen und das bestärkende Lernen.

#### Verschiedene Formen des Lernens

Beim **überwachten Lernen** werden Maschinen mit einer großen Menge an beispielhaften Ein- und Ausgabewerten trainiert [7]. Aus der Beziehung zwischen den Ein- und Ausgabewerten kann ein funktionaler Zusammenhang gebildet werden, der auch eine Vorhersage von Ausgabewerten bei zukünftigen bisher unbekannten Eingabewerten erlaubt. Die Identifikation dieses funktionalen Zusammenhangs zwischen Ein- und Ausgabewerten wird als Regression bezeichnet. Demgegenüber dient die Klassifikation der Zuordnung von Merkmalen, die aus den Eingabewerten gewonnen werden, zu Objektklassen als Ausgabewerte eines Klassifikators. Die Grundlage hierfür bilden Methoden der Mustererkennung. Für das überwachte Lernen dieses Zusammenhangs bedarf es einer ausreichenden Datenmenge, in denen die Beziehung zwischen Merkmalen und Objektklassen bereits bekannt ist. Bei der Erfassung der Ein- und Ausgabewerte in der Praxis sind die zu den Merkmalen gehörigen Objektklassen jedoch häufig nicht bekannt. In diesem Fall muss die Beziehung zwischen den Daten durch das sogenannte „Annotieren“ der Daten nachträglich hergestellt werden. Häufig wird dieser Vorgang auch als „Labeln“ der Daten bezeichnet.

Auch beim **unüberwachten Lernen** wird eine beispielhafte Datenmenge benötigt, jedoch ohne Ausgabewerte. Stattdessen wird erlernt, wie „typische“ Daten oder Datengruppen aussehen. Die Beispieldaten lassen sich zwar mit wenig Aufwand erstellen, decken jedoch nicht alle Anwendungsfälle ab [7].

Das **bestärkende Lernen** basiert auf Belohnungsprinzipien, die zu Veränderungen von Lösungen im Sinne der Optimierung führen. Teilschritte einer Lösung werden anhand von Punktzahlen bewertet, wobei eine maximale Punktzahl angestrebt wird [7]. Eine wesentliche Herausforderung stellt jedoch die Identifikation geeigneter Belohnungsmechanismen dar. Abbildung 1 stellt die Beziehung der vorgehend beschriebenen Begriffe untereinander dar.

Wie in der Einleitung erläutert, sieht die WGP in den Technologien des ML ein besonderes Potenzial zur systematischen Generierung neuer Wertschöpfung durch gezielten Einsatz von Domänen- und Prozesswissen der Produktion. Neben den vorangehend erläuterten, grundlegenden Begriffen aus den Bereichen KI, ML und Data Mining sollen daher nachfolgend auch Begriffe erläutert werden, die in der praktischen Umsetzung von ML in der Produktion an Bedeutung gewinnen und mit der Integration von Domänenwissen in Beziehung stehen.

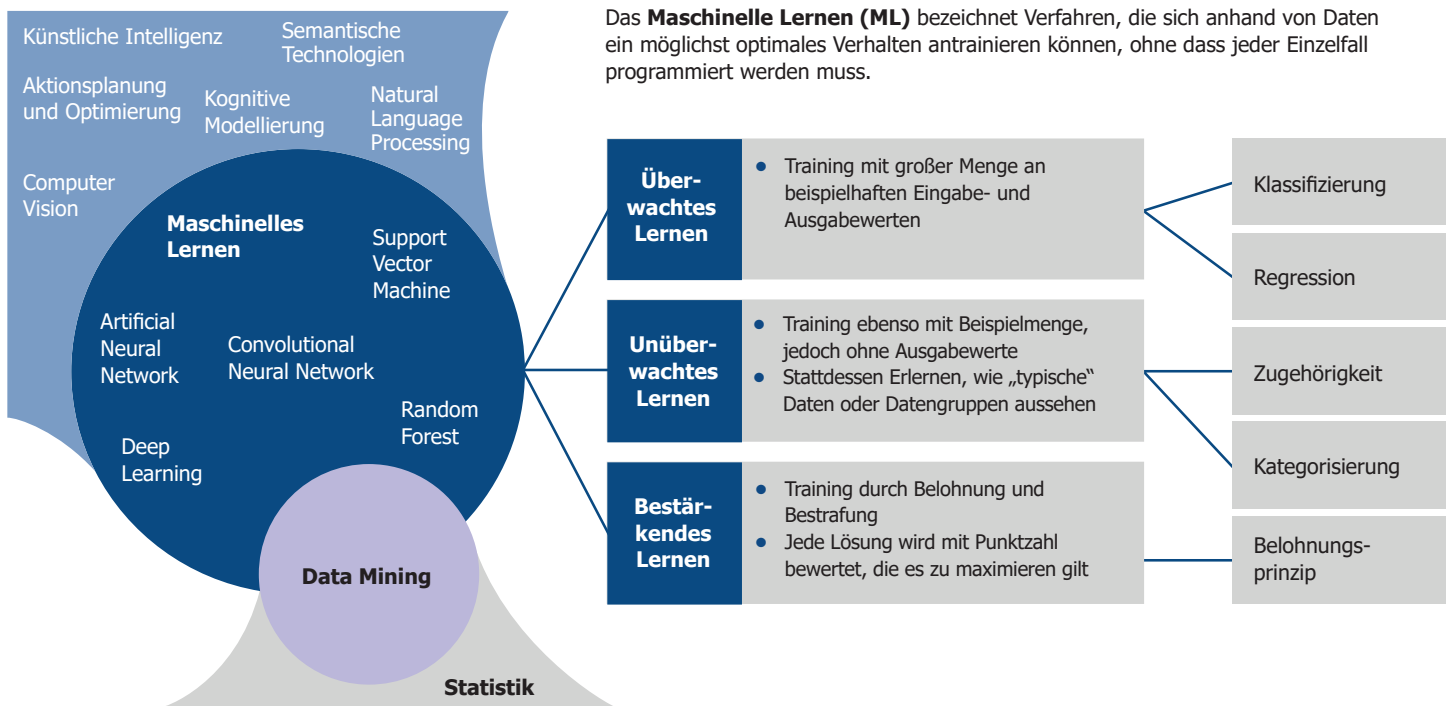


Abbildung 1: Zusammenhang zwischen KI-Feldern und Begriffen in Anlehnung an [7], [8]

### Augmentation

Trotz erheblicher Fortschritte in der Datengewinnung durch Vernetzung von Maschinen und Anlagen im Zuge von Industrie 4.0 bestehen Herausforderungen zur Anwendung neuester maschineller Lernverfahren in der Produktion. Eine wesentliche Herausforderung liegt darin, dass je nach betrachtetem Prozess die zum ML benötigten Datenmengen nur über längere Zeiträume gewonnen werden können. Ein Lösungsansatz besteht darin, bereits verfügbare Daten zu augmentieren, d. h. gezielt zu modifizieren, um so die Datenbasis zu vergrößern. Insbesondere in der Bilderkennung findet Augmentierung Anwendung, beispielsweise durch Rotation oder Veränderung von Helligkeit und Perspektive von Bilddaten.

### Annotieren / Labeln von Daten

Durch das Annotieren bzw. Labeln werden Eingabewerte gezielt mit Wissen über die darin enthaltenen Informationen als gewünschte Ausgabewerte verbunden. Dieser Prozess ist Voraussetzung für das überwachtes Lernen der Beziehung zwischen Ein- und Ausgabewerten. Die rechnergestützte Vereinfachung und Automatisierung der Annotierung von Daten für das überwachtes Lernen rückt aufgrund des in der Praxis häufig hohen Zeitaufwandes beim Labeln zunehmend in den Fokus der KI-Forschung [9].

### Blackbox- / Greybox- / Whitebox-Modelle

Die Begriffe "Blackbox" und "Whitebox" stehen für den unterschiedlichen Grad an Wissen über das Ein- und Ausgangsverhalten von Systemen. Während bei Whitebox-Modellen das Verhalten zwischen Ein- und Ausgangsgrößen vollständig erklärt werden kann, lässt sich dieses bei Blackbox-Modellen lediglich aufgrund von Beobachtungen beschreiben. Der Vorteil der Berechenbarkeit bei Whitebox-Modellen wird in der Regel mit einem hohen Aufwand zu deren Erstellung erkaufte. Demgegenüber ist der Aufwand für das maschinelle Erlernen von Blackbox-Modellen häufig deutlich geringer, jedoch verbunden mit der Unsicherheit bzgl. der Zuverlässigkeit des Modells. Dies gilt insbesondere für bisher unbekannte Eingangsgrößen. Greybox-Modelle, bestehend aus Elementen von Whitebox- und Blackbox-Modellen, bieten die Möglichkeit, die Vorteile beider Modellansätze bei adäquatem Abgleich zwischen Modellierungsaufwand und Zuverlässigkeit zu verbinden. Sie profitieren damit von den Leistungssteigerungen des ML zur automatisierten Modellierung. Gleichzeitig bieten sie jedoch auch die Möglichkeit, an entscheidenden Stellen domänenspezifisches Wissen über Prozesse, Maschinen- und Anlagenverhalten in deterministischen Beschreibungsformen zu integrieren.



## 4 Wertschöpfungspotenziale von KI in der Produktion

Das produzierende Gewerbe bildet eine tragende Säule der deutschen Wirtschaft und leistet einen wesentlichen Beitrag zum Wohlstand in Deutschland. Eine im Januar 2018 veröffentlichte Studie im Auftrag des Bundesministeriums für Wirtschaft und Energie (BMWi) sagt für diesen Sektor für die Jahre 2019 bis 2023 ein **zusätzliches KI-induziertes Wachstum** von 31,4 Mrd. EUR voraus [8]. Anhand solcher Analysen lässt sich der wachsende Einfluss von Technologien der KI auch auf die Produktionstechnik ablesen. Ein sehr häufig genanntes Anwendungsbeispiel von KI in der Produktion ist die vorausschauende Wartung und Instandhaltung (Predictive Maintenance) von Maschinen und Anlagen. Dieses betrifft jedoch nur einen kleinen Teil des Spektrums möglicher produktionstechnischer Anwendungen in der Zukunft.

Die Innovations- und Wettbewerbsfähigkeit produzierender Unternehmen basiert in erheblichem Maße auf einem hervorragend ausgebildeten technologischen Wissen zu Produktionsprozessen, -maschinen und -anlagen. Es stellt sich daher die **entscheidende Frage**, die dieser Standpunkt adressiert:

Wie kann dieses wettbewerbsentscheidende produktionstechnische Wissen **systematisch und methodisch** mit neuen technologischen Entwicklungen der KI verbunden werden, um **zielgerichtet Innovationen** zu fördern, mit denen der Wert von Produkten sowie die Effizienz von Prozessen, Maschinen und Anlagen bis hin zu Wertschöpfungsnetzwerken in der Produktion gesteigert werden?

Eine mögliche Antwort auf diese Frage ergibt sich, wenn man insbesondere die Entwicklungen bei ML-Methoden der vergangenen Jahre betrachtet. Hierbei sind zwei grundlegende Effekte zu beobachten.

### Leistungssteigerungen des ML

Der erste Effekt betrifft die deutlichen Leistungssteigerungen der ML-Methoden. So sind beispielsweise durch die Entwicklung der sogenannten Convolutional Neural Networks (CNNs) in repräsentativen Benchmarks die **Fehlerraten bei der Bilderkennung von knapp 30 % im Jahr 2010 auf ca. 3 % im Jahr 2017 gesunken** (s. Abbildung 2) [10].




Abbildung 2: Fortschritte der Bilderkennung seit dem Jahr 2010 (Abbildung in Anlehnung an [10]; Daten aus [11])

### Breite Verfügbarkeit von Werkzeugen zum ML

Der zweite Effekt, der zur rasanten Entwicklung des ML beigetragen hat, ist die vielfältige Verfügbarkeit von Werkzeugen des ML. Der VDMA gibt in seinem „Quick Guide Machine Learning im Maschinen- und Anlagenbau“ [7] eine Übersicht über mehr als 20 KI-Frameworks und Plattformen für die Datenanalyse und das ML, von denen viele als Open Source zur Verfügung stehen. Eine große Zahl dieser Werkzeuge ist so gestaltet, dass mithilfe guten softwaretechnischen Grundwissens bereits nach verhältnismäßig kurzer Zeit einfache Beispielanwendungen realisiert werden können. Diese Werkzeuge werden durch eine breite Palette von Anleitungen ergänzt, die zumeist als digitale Lernumgebungen mit integrierten Videostreams im Internet verfügbar sind. Die WGP nutzt einen Teil dieser Werkzeuge in den in Kapitel 5 beschriebenen Anwendungen aus den Forschungsarbeiten.

### Verbesserte Kosten-/Nutzen-Verhältnisse

Die Verbindung beider Effekte führt dazu, dass sich das Kosten-/Nutzen-Verhältnis dieser Werkzeuge und der zugrunde liegenden Technologien für die produktionstechnische Anwendung beständig verbessert. Dies wiederum hat zur Folge, dass sich auch der Nutzen von Maßnahmen stetig erhöht, die im engen Zusammenhang mit der Anwendung von KI und insbesondere Verfahren des ML stehen. Die folgende Abbildung 3 zeigt diesen Zusammenhang.

Im Zentrum stehen dabei die **Werkzeuge und Technologien des ML** mit ihrer Fähigkeit, **Modelle erlernen zu können**, auf deren Basis sich Vorhersagen treffen lassen. Beispiele hierfür sind die Zugehörigkeit von Daten/Mustern zu einem Objekt (Klassifikation) oder zukünftige Veränderungen der Daten.

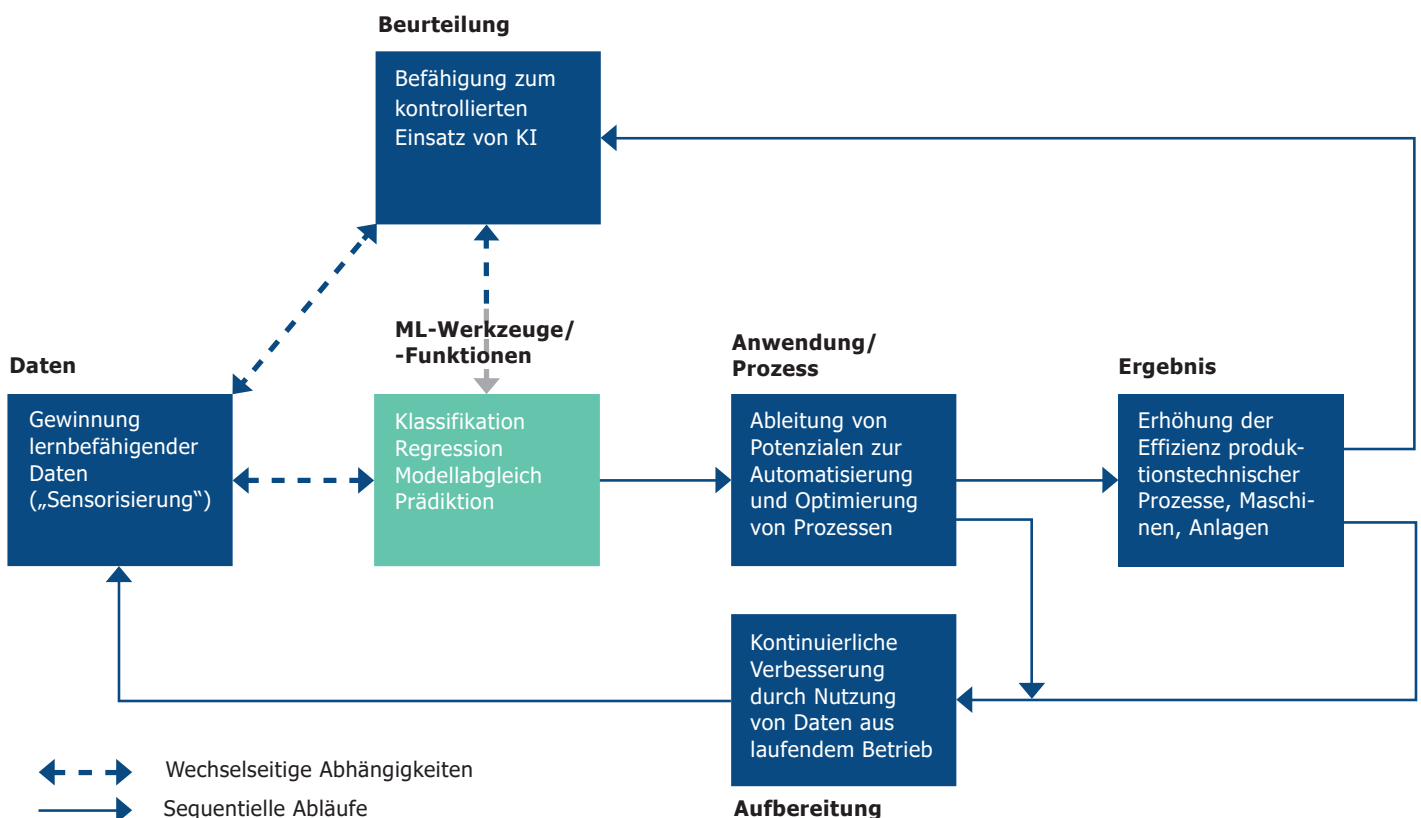


Abbildung 3: Wertschöpfungskomponenten von KI in der Produktion

Hierdurch steigt **auch der Nutzen von Maßnahmen bzw. Prozessen**, die mit diesen KI-Funktionen im direkten Zusammenhang stehen, wie die systematische Gewinnung von Trainingsdaten, die Ableitung von Potenzialen zur Automatisierung und Optimierung, das stetige Weiterlernen aus den verbesserten Prozessen und nicht zuletzt die Beurteilung der Zuverlässigkeit und Robustheit erlernter Zusammenhänge vor deren Nutzung in produktionstechnischen Prozessen, Maschinen und Anlagen.

In den Bereichen Daten, Anwendung und Beurteilung zeigen sich die besonderen Potenziale und Notwendigkeiten zur systematischen Integration spezifischen produktionstechnischen Wissens, die im Folgenden näher betrachtet werden.

## 4.1 Daten

Viele der Entwicklungen aus dem Bereich Industrie 4.0 zielten in den vergangenen Jahren darauf ab, Maschinen und Anlagen deutlich stärker zu vernetzen, um durch den so möglichen Austausch von Daten, Prozessen, Maschinen und Anlagen effizienter als bisher steuern, regeln oder überwachen zu können. Diese Forschungs- und Entwicklungsarbeiten zur „Sensorisierung“ von Maschinen und Anlagen bilden heute eine ausgezeichnete Grundlage für die Datengewinnung zum ML, beispielsweise zur Früherkennung von Fehlern in komplexen Produktionsprozessen.

Bei der **Auswahl und Verwendung der Daten** für das ML ist jedoch von besonderer Bedeutung, vorhandenes produktionstechnisches Wissen über die zugrundeliegenden Prozesse in die Modelle einfließen zu lassen, die anhand der Daten erlernt werden sollen. Sollen beispielsweise Korrelationen und/oder Kausalitäten zwischen Prozessgrößen auf der Basis von Methoden der Mustererkennung automatisch erkannt werden, so bedarf es in der Regel spezifischer Kompetenzen zur Prozesstechnologie, Signalverarbeitung, Maschinendynamik oder Sensortechnik im jeweiligen produktionstechnischen Kontext.

Ein weiteres Potenzial zur Gewinnung von Daten liegt in der **Simulation produktionstechnischer Prozesse**. Dies ist unter anderem dann interessant, wenn keine entsprechenden Sensordaten vorliegen, der Aufwand zur Sensorisierung zu groß ist oder die Daten nicht dicht genug am Prozess gewonnen werden können. Besonders interessant ist eine Simulation jedoch, wenn Prozessdaten nur über einen sehr langen Zeitraum gewonnen werden können. Gerade neue Verfahren des ML, wie das Deep Learning, benötigen in der Regel große Datenmengen, um ihre tiefen Netzstrukturen anlernen zu können. Daher werden in Forschungsarbeiten zunehmend auch auf Grundlage von Simulation generierte Daten zum Training verwendet.

Insbesondere in der **Bildanalyse** wird dem Problem begrenzter Datenvolumina häufig zusätzlich dadurch begegnet, dass Daten „augmentiert“ werden, also vorhandene Daten gezielt verändert werden, um hierdurch die Datenbasis zu erweitern. Bei Bilddaten geschieht dies beispielsweise durch die Rotation von Bildern oder die Veränderung von Bildeigenschaften wie Helligkeit oder Kontrast (siehe Kapitel 3).

Aufgrund des zunehmenden Wertes von Daten als Basis neuer auf maschinellen Lernverfahren basierender Wertschöpfungsprozesse in der Produktion bedarf es zudem **einer systematischen Identifikation der Datenquellen**. Vielfach sind in Produktionsprozessen bereits implizites Wissen und Information vorhanden, ohne dass diese bisher für maschinelle Lernverfahren verwendet werden. Ein typisches Beispiel hierfür sind Daten aus der optischen Qualitätskontrolle und Bauteilprüfung. Die in Prüf- und Sortierprozessen in der Regel binäre **Entscheidung über die Qualität des Bauteils** „in Ordnung“ (i. O.) oder „nicht in Ordnung“ (n. i. O.) wird bisher nur selten **mit bereits vorhandenen digitalen Daten über das Bauteil in Beziehung gesetzt** und gespeichert. Diese zusammenhängende Speicherung von Daten und Entscheidungen – das sogenannte Annotieren oder Labeln der Daten – ist jedoch eine wertvolle Voraussetzung für das überwachte Lernen zur automatisierten Qualitätskontrolle. Dieser Wert der zusammenhängenden digitalen Speicherung von Daten (z. B. Bilddaten) und Wissen (i. O. / n. i. O.) für maschinelle Lernverfahren ist in der produktionstechnischen Praxis jedoch noch vergleichsweise wenig bekannt. Es muss daher einerseits verstärkt Expertise hierzu bei den Anwendern in der Produktion aufgebaut werden. Andererseits bedarf es jedoch einer bisher nicht vorhandenen Methodik zur Identifikation der Datenquellen, aus denen sich systematisch Potenziale zur Nutzung von KI-Technologien ableiten lassen. Beispiele hierfür sind vielfach vorhandene semantische Beschreibungen aus Normen, eClass-Modellen oder aus Anlagenmodellen auf der Basis von AutomationML.

## 4.2 Anwendung

Die bereits genannte Studie im Auftrag des BMWi [8] nennt eine Vielzahl von Anwendungen von KI in der Produktion wie

- Predictive Analytics (z. B. Überwachung und Wartung von Produktionsanlagen),
- optimiertes Ressourcenmanagement (z. B. Optimierung von Produktions- und Fertigungsplänen),
- Qualitätskontrolle (z. B. Prüfung der Beschaffenheit von Bauteilen),
- intelligente Assistenzsysteme (z. B. Unterstützung bei Fertigungsprozessen),
- Wissensmanagement (z. B. Datenmodelle für komplexe Engineering-Prozesse),

- Robotik (z. B. lernende, selbstregulierende Greifersysteme),
- autonomes Fahren und Fliegen (z. B. fahrerlose Transportsysteme),
- intelligente Automatisierung (z. B. Automatisierung von Routineprozessen in Fertigung und Montage) sowie
- intelligente Sensorik (z. B. Vorverarbeitung der Daten beim Monitoring von Produktionsanlagen).

Kapitel 6 gibt eine Übersicht über die breite Palette produktionstechnischer Anwendungen aus konkreten Forschungs- und Entwicklungsarbeiten der WGP-Institute.

Wie bereits zu Anfang des Kapitels 4 formuliert, werden von den aufgeführten und auch weiteren Anwendungen erhebliche zukünftige Wertschöpfungspotenziale erwartet. Ein wettbewerbsentscheidender Faktor wird daher sein, diese Potenziale auf Grundlage produktionstechnischer Kompetenzen systematisch zu identifizieren und zu erschließen.

### Systematische Verbindung von „tasks“ und „skills“

Eine methodische Identifikation gelingt durch das Zusammenführen von Aufgaben der Optimierung und Automatisierung in der Produktion einerseits und spezifischen Fähigkeiten aus dem Bereich KI/ML andererseits, d. h. dem Zusammenführen von „tasks“ und „skills“. Die folgende Abbildung 4 verdeutlicht diesen Zusammenhang am Beispiel verschiedener Funktionen aus dem Bereich der Handhabung. Wie in vielen Bereichen der Produktionstechnik sind auch bei den Handhabungsfunktionen die einzelnen Aufgabenfelder systematisch gegliedert (VDI 2860). Dies erlaubt eine systematische Zuordnung zu spezifischen Fähigkeiten, wie sie beispielsweise für komplexe Montageoperationen benötigt werden. Hierbei werden nicht zuletzt aufgrund der wachsenden Anforderungen an die Flexibilität häufig unterschiedliche menschliche Fähigkeiten (Lernfähigkeit, motorische Kontrolle, haptische Fähigkeiten) eingesetzt, wie sie im unteren Bereich von Abbildung 4 dargestellt sind. Zwischen den zusammengesetzten Handhabungsfunktionen („tasks“) und den menschlichen Fähigkeiten („skills“) lassen sich nun systematisch die verschiedenen Beziehungen analysieren. Hierbei bedarf es entsprechender produktionstechnischer Kompetenzen. In der zweiten Stufe ist unter Berücksichtigung entsprechender Kompetenzen aus

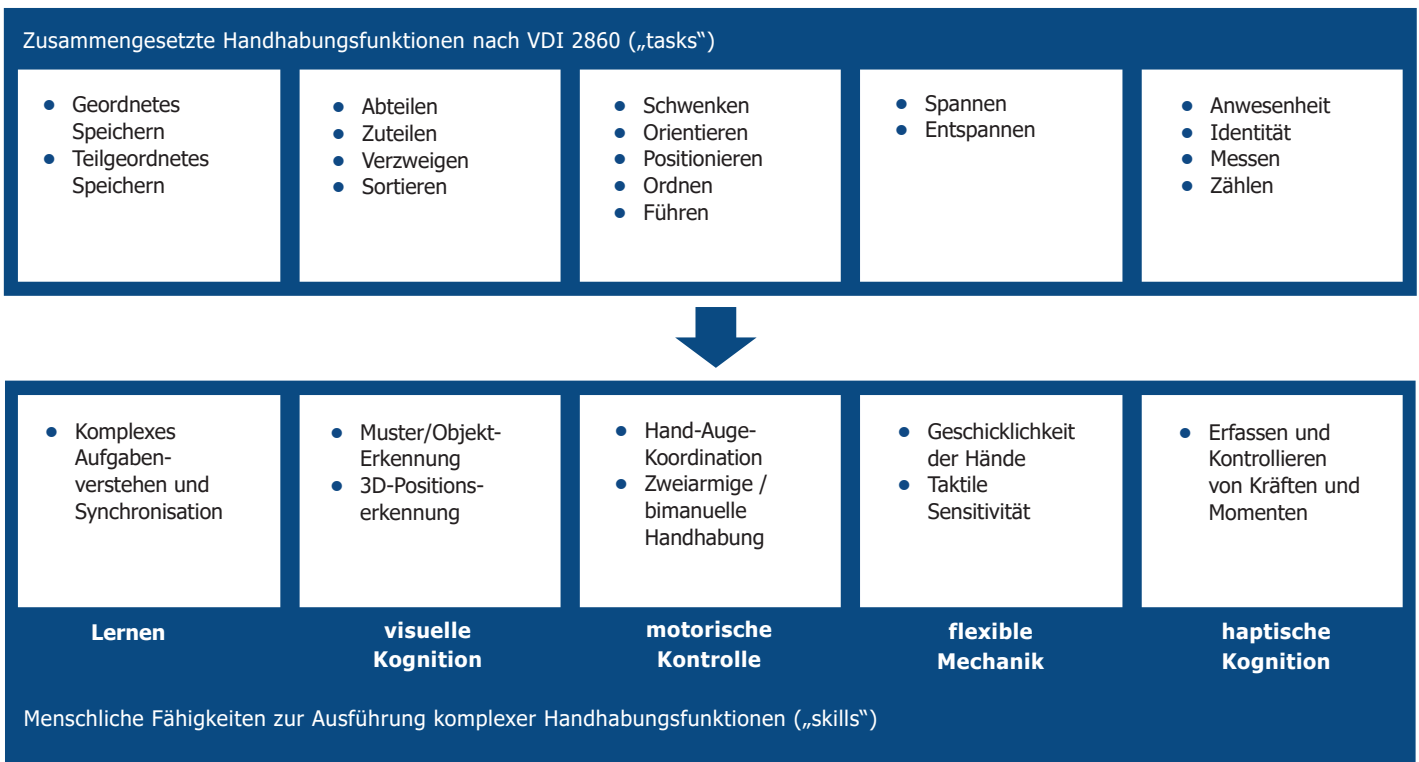


Abbildung 4: Systematische Abbildung von „tasks“ (produktionstechnische Kompetenz) und „skills“ (KI-Kompetenz) am Beispiel von Handhabungsfunktionen

dem Bereich KI zu bewerten, inwieweit diese menschlichen Fähigkeiten durch die aktuellen oder auch absehbar zu erwartenden Fähigkeiten im Bereich KI/ML abgebildet werden können. Anschließend ist mit domänenspezifisch produktionstechnischer Kompetenz zu analysieren, wie sich diese Bewertung in einem Gesamtrahmen entsprechend Abbildung 4 mit den Erfordernissen beispielsweise zur Gewinnung von Daten oder der Abschätzung der Zuverlässigkeit integrierten lässt.

Darüber hinaus existierten für produktionstechnische Anwendungen noch eine Reihe weiterer interessanter Anwendungspotenziale, u. a.

- Ableitung von technologischen Zusammenhängen aus gelernten Daten,
- Ableiten und Lernen logischer Zusammenhänge aus Prozessabläufen,
- Integration semantischen Wissens im Sinne „hybrider KI“,
- Regelung komplexer, nichtlinearer Prozesse (adaptive Regelung, (modell-)prädiktive Regelung, iterativ lernende Regelung usw.) und
- Lernen der Anpassung an den Menschen in der Mensch-Maschine-Interaktion; Vereinfachung von Schnittstellen zwischen Mensch und Maschine auf Basis der deutlichen Leistungssteigerungen in Feldern wie z. B. Spracherkennung.

#### Systematische Entwicklung von Assistenzfunktionen

Ein besonderes Anwendungspotenzial des letztgenannten Punktes liegt darin, Fähigkeiten der KI gezielt zur Entwicklung von Assistenzfunktionen zu nutzen, die auf allen Ebenen der Automatisierungspyramide abgeleitet werden können. Wesentliche Anwendungsfelder hierbei sind

- assistiertes Engineering (z. B. KI-unterstützte Assistenz bei der Auswahl von Betriebsmitteln oder der Auswahl von Kombinationen von Materialien und Technologien). Hierbei können Fähigkeiten maschineller Lernverfahren genutzt werden, um komplexe Zusammenhänge zu identifizieren und damit für den Entwickler bisher nicht bekannte oder erkennbare Lösungsoptionen transparent zu machen,
- Mensch-Roboter-Kollaboration (z. B. verbesserte Adaption des Roboters an den Menschen durch Lernen menschlicher Handlungsmuster und Bewegungsabläufe) sowie
- assistierte Roboterprogrammierung.

Die Nutzung von KI zur Entwicklung von Assistenzsystemen und -funktionen ist zudem oft dort interessant, wo die Datenbasis zum ML erst über eine längere Zeit aufgebaut werden muss oder aufgrund der Rahmenbedingungen der Anwendung nicht in umfangreicher Form aufgebaut werden kann. Im sechsten Kapitel wird dies an einem Anwendungsbeispiel zur Bauteilidentifikation näher erläutert.

### 4.3 Beurteilung

Die Möglichkeit, Maschinen lernen zu lassen, führt zu der Frage, wie maschinell lernende Systeme bezüglich ihrer Zuverlässigkeit und Robustheit beurteilt werden können. Einerseits zeigen KI-Systeme in bestimmten Domänen – wie zum Beispiel die Bildanalyse in spezifischen Anwendungen der medizinischen Diagnostik – bereits heute **Fähigkeiten, die den menschlichen Fähigkeiten überlegen sind**. Andererseits ist die Struktur solcher Systeme so komplex, dass sich deren Verhalten nur noch statistisch beschreiben, nicht jedoch deterministisch begründen oder gar beweisen lässt. Dies erschwert maßgeblich die **verantwortliche Entscheidung über den Einsatz** der Verfahren in der Produktion und somit die Ausschöpfung der neuen Wertschöpfungspotenziale. Gleichzeitig wächst an dieser Stelle jedoch auch der Wert einer qualifizierten menschlichen Beurteilung und Entscheidung.

Anforderungen an neue Qualifikationen entstehen zukünftig auch zur **Qualitätssicherung von Daten**, die für Lernprozesse in der Produktion verwendet werden sollen. Beispielsweise müssen Experten beurteilen, wie repräsentativ Lerndaten sind, die Störungen unterliegen und wie hierdurch die Güte des erlernten Modells beeinflusst wird. Die Herausforderung ist noch deutlich größer, wenn das Potenzial genutzt werden soll, um Modelle auf Grundlage maschineller Lernverfahren stetig durch neue Prozessdaten zu verbessern (siehe hierzu auch das folgende Teilkapitel). **Gerade bei solchen Feedbackprozessen** besteht ein hohes Potenzial zur kontinuierlichen Leistungssteigerung. Das Dilemma ist jedoch, dass die Gefahr einer Verschlechterung durch neue Daten umso größer ist, je höher die Erkennungsfähigkeit ausgebildet ist. Die Daten müssen daher einer Qualitätskontrolle unterzogen werden, bevor sie in weitere Lernprozesse einbezogen werden.

Es ist davon auszugehen, dass noch in absehbarer Zukunft die Verantwortung für den Einsatz von KI in der Produktion und die dabei verwendeten Daten durch den Menschen getragen wird. Damit bedarf es jedoch einer gezielten Qualifikation solcher Entscheider. **Denkbar ist das Berufsbild eines „KI-Ingenieurs“** mit dem Schwerpunkt Produktion oder in der Vorstufe eines Produktionsingenieurs mit einem Schwerpunkt im Bereich maschineller Lernverfahren. In beiden Fällen sind die heutigen Ausbildungsmodelle auf universitärer Ebene, aber noch deutlicher im Bereich der Berufsausbildung anzupassen. Nur dann lassen sich neue Wertschöpfungspotenziale der sich schnell entwickelnden maschinellen Lernverfahren nutzen. Die Geschwindigkeit, mit der dies im Unternehmen gelingt, wird zukünftig deutlich stärker als bisher über dessen Wettbewerbsfähigkeit entscheiden.



## 5 Datengetriebene vs. prozessgetriebene Anwendung von KI/ML

### 4.4 Training und Feedback

Sobald vorhandene Daten in Trainingsprozessen verarbeitet wurden, geht deren Wert auf das erlernte Modell über. Für weitere Verbesserungen des Modells und damit weiteren Nutzen **bedarf es dann Daten aus nachfolgenden Fertigungsaufträgen**. Dies führt zu der Frage, wie diese im Sinne einer laufenden Verbesserung der Lernprozesse systematisch durch Rückführung (Feedback) aus dem Produktionsprozess im Sinne einer Regelkreisstruktur genutzt werden können.

**Regelkreisstrukturen** finden sich auf allen Ebenen der Produktion von Echtzeitregelung auf dem Shopfloor bis hin zu Qualitätsregelreisen. Dementsprechend bestehen auch für die systematische Nutzung von Feedbackprozessen zum kontinuierlichen ML in der Produktion generell gute Voraussetzungen im Sinne der Akzeptanz und Expertise. Allerdings **fehlt es hierzu bisher an einer Methodik und an Erfahrung**.

Eine besondere Herausforderung bildet zudem das Dilemma, dass bei stetig verbesserten Systemleistungen gleichzeitig auch das Risiko wächst, dass das trainierte System sich auch wieder in der Gesamtleistung verschlechtert. Umso wichtiger ist an dieser Stelle die Kontrolle der Qualität der Lerndaten aus dem laufenden Betrieb sowie die fortlaufende Validierung der Systemleistung. Wie bereits erwähnt, bedarf es hierfür **neuer Formen der Aus- und Weiterbildung** von KI-Experten in der Produktion.

Wie im vorangehenden Kapitel anhand von Abbildung 2 erläutert, erhöht die Entwicklung oft frei verfügbarer leistungsfähiger Softwareumgebungen (Frameworks) für KI/ML den Wert domänenspezifischer Kompetenzen zur Datengewinnung, Beurteilung und Anwendung für und von maschinellen Lernverfahren. Insbesondere der Wert ihrer produktionstechnischen Daten wird inzwischen von vielen Unternehmen erkannt. **Der Umgang mit diesen Daten ist jedoch durchaus unterschiedlich**. Während viele Unternehmen zunächst Daten erfassen, um sie für spätere Anwendungen zu sichern, versuchen andere Unternehmen bereits gezielt, potenziell in den Daten aggregierte Information im Rahmen der sogenannten „intelligenten Datenanalyse“ zu erschließen. Hierbei handelt es sich also um einen **explorativen Ansatz, in Kapitel 1 auch als „Push“-Ansatz bezeichnet**, der getrieben ist durch eine informationstechnisch datenorientierte Sicht. Aufgrund des abstrakten Charakters dieser Vorgehensweise bedarf es vergleichsweise wenig domänenspezifischen Wissens. Der „Push“-Ansatz ist also auch mit geringer produktionstechnischer Kompetenz anwendbar. Dies kann als Vorteil betrachtet werden. Es ist jedoch zugleich ein Nachteil, dass die Gewinnung der Daten häufig **nicht konsequent vom Produktionsprozess ausgehend gedacht** wird.

Viele der bisherigen Anwendungen maschineller Lernverfahren in der Produktion folgen dem „Push“-Ansatz, sind also datengetrieben. Gerade im Zusammenhang mit der „Sensorisierung“ von Maschinen und Anlagen im Zuge von Industrie 4.0 werden in Unternehmen umfangreiche Daten gesammelt. Die explorative Vorgehensweise des „Push“-Ansatzes ermöglicht zwar auch einen Informationsgewinn, der zu einer Verbesserung des Produktionsprozesses führen kann, er ist jedoch aufgrund seiner datengetriebenen Perspektive nicht gezielt darauf ausgerichtet. Damit bietet er auch nur **eingeschränkte Möglichkeiten, wertvolles Wissen über den Prozess einzubeziehen**.

Anders verhält es sich beim produktionstechnisch prozessorientierten „Pull“-Ansatz. Dieser geht vom Produktionsprozess, den dabei verwendeten Maschinen, dem Umfeld und nicht zuletzt dem Werker aus und zielt in der Regel auf die Überwachung, Regelung oder Optimierung des Prozesses. Dies hat wesentliche Konsequenzen für die Frage, auf welchen Daten gezielt maschinelle Lernverfahren angewendet werden und wie diese Daten gewonnen werden können. Korrelation, Wechselwirkung und Kausalitäten derjenigen Rahmenbedingungen, die den Prozess maßgeblich beeinflussen (Prozess, Maschine, Material, Umgebung, Mensch), bilden wertvolles Domänenwissen. Mit diesem Wissen können Ansätze des ML gezielt eingesetzt werden.

In der Zukunft besteht eine wissenschaftliche Herausforderung aber noch darin, die unterschiedlichen Repräsentationsformen von Daten, die mit diesen Rahmenbedingungen und Einflussgrößen verbunden sind, in

geeigneten Prozessmodellen und maschinellen Lernverfahren, die diese im Sinne von Greybox-Ansätzen nutzen können, abzubilden.

Gegenüber dem informationstechnisch datengetriebenen „Push“-Ansatz bietet der produktionstechnisch prozessorientierte **„Pull“-Ansatz somit wesentlich mehr Potenzial**, das in der Produktion vorhandene Domänenwissen systematisch im Sinne neuer Wertschöpfungspotenziale zu nutzen.

Der vom Prozess her gedachte produktionstechnische Ansatz zur Nutzung maschineller Lernverfahren stellt sich gegenüber der in Abbildung 3 beschriebenen Struktur in veränderter Form dar (Abbildung 5).

Grundlegend neue Wertschöpfungspotenziale zeigen sich hierbei konkret in Form der systematischen „Sensorisierung“ des Prozesses für das ML, der Optimierung basierend auf potenziell leistungsfähigeren gelernten Modellen insbesondere komplexer Prozesse sowie der Bewertung der Zuverlässigkeit dieses Regelkreises in der konkreten produktionstechnischen Anwendung.

Ein Ziel dieses Standpunktes liegt darin, **dieses Potenzial prozessorientierter Vorgehensweisen** in der Nutzung maschineller Lernverfahren **anhand von Beispielen und den daraus ableitbaren grundlegenden Methodiken aufzuzeigen**.

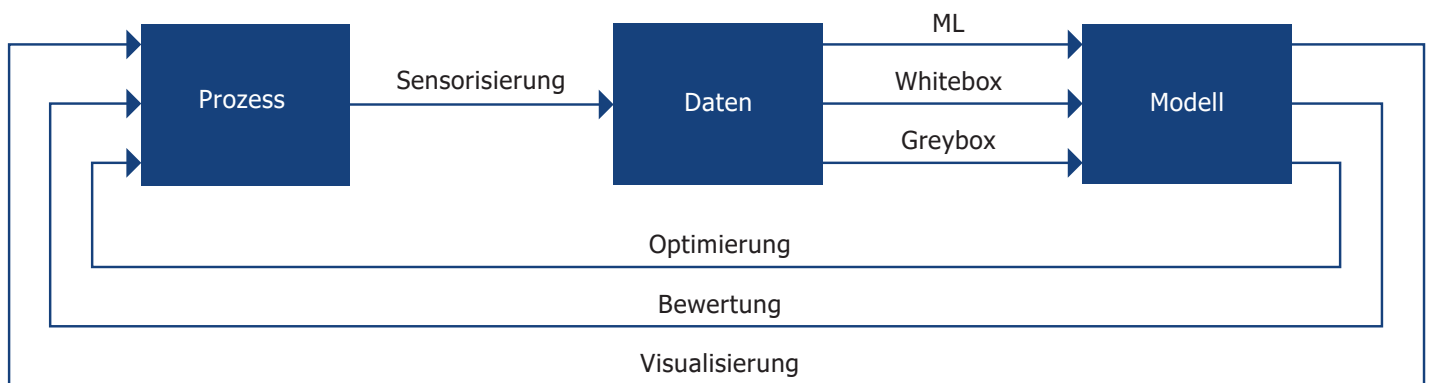


Abbildung 5: Produktionstechnisch prozessorientierter „Pull“-Ansatz zur Nutzung maschineller Lernverfahren in Anlehnung an [10]

## 6 Anwendungsbeispiele aus der produktionstechnischen Forschung der WGP

Eine Besonderheit des in den Standpunkt eingeflossenen Erfahrungswissens ist, dass die Forschungs- und Entwicklungsleistungen der WGP-Institute typischerweise prozessorientiert sind. Das heißt, sie folgen dem „Pull“-Ansatz, bei dem der Ursprung für die Anwendung von KI/ML-Verfahren aus einem konkreten Bedarf resultiert, Produktionsprozesse zu optimieren. In den Forschungsarbeiten der WGP werden Methoden der KI und insbesondere des ML heute intensiv zur Optimierung produktionstechnischer Prozesse und Anlagen genutzt. Die Schwerpunkte der Anwendungen liegen dabei in den Bereichen CNC-Maschinen/-bearbeitung, Handhabung/Montage/Robotik und Materialfluss/Logistik.

Tabelle 1 zeigt eine Auswahl der rapide zunehmenden Anzahl von Forschungsarbeiten der WGP auf dem Gebiet der KI-unterstützten Produktion. Auch weltweit ist im Bereich der Produktionsforschung eine deutliche Zunahme der Forschungsaktivitäten in diesem Bereich zu verzeichnen. Dies zeigt sich unter anderem auch an den sprunghaft **gestiegenen Zahlen von KI-bezogenen Veröffentlichungen in den führenden internationalen Journals** der Produktionstechnik.

Tabelle 1: Anwendungsbeispiele des ML in der Produktion aus Forschungsarbeiten der WGP

Anwendungsdomäne	Anwendungsbeispiel	Realisierung mit ML	Eingangsgröße	Ausgangsgrößen	Ref.
<b>CNC-Maschinen/ -bearbeitung</b>					
Qualitätskontrolle/ Prozessoptimierung	Prozessbegleitende Bewertung der Oberflächenqualität	Prädiktion der Oberflächenrauheit der Bearbeitung durch KNN	Zerspanparameter, Werkzeugparameter, Steuerungsdaten	Mittlere Oberflächenrauheit	[12]
Qualitätskontrolle/ Prozessoptimierung	Metall/Nichtmetall-Klassifikation von Partikeln zur Sauberkeitsanalyse	Deep-Learning-Modell basierend auf einem Inception-ResNetV2-Modell	Bilddaten von metallischen und nicht-metallischen Partikeln	Metall/Nichtmetall-Klassifikation	[13]
Qualitätskontrolle/ Prozessoptimierung	Vorhersage von Geometrie und Oberflächenrauheit sowie Optimierung der Prozessparameter beim Bohren	Bayes'sche Netze / GeNIe	Bohrparameter, Kräfte, Momente	Werkzeugverschleißradius, Oberflächenrauheit und Rundheit der Bohrung	[14]
Qualitätskontrolle	In-Prozess-Identifikation von Oberflächenbeschädigungen	Unüberwachtes Lernen	Bilddaten der Bauteiloberflächen	Lokalisierte Beschädigungen	[15]
Prozessüberwachung	Vorhersage von Zerspankräften	Anlernen eines KNN in den ersten Sekunden eines Zerspanprozesses	Zerspanparameter, Antriebsströme, Geschwindigkeit, Beschleunigung, Ruck	Zerspankräfte	[16], [17]
Optimierung Maschinenelemente	Optimierung semiaktiver Dämpfungskomponenten	Genetischer Algorithmus	Daten aus Finite-Elemente-Methode-Modellen (FEM-Modellen)	Optimierte Kammerstrukturen für Maschinenschlitten	[18]

Anwendungsdomäne	Anwendungsbeispiel	Realisierung mit ML	Eingangsgrößen	Ausgangsgröße	Ref.
<b>CNC-Maschinen/ -bearbeitung</b>					
Condition Monitoring	Condition Monitoring an Kugelgewindetrieben	Zustandsklassifizierung mit Support Vector Machine (SVM), weitere Klassifikatoren getestet	Beschleunigung (3-Achsmikro-elektro-mechanischer System-Sensor, auch 3-Achs-MEMS-Sensor)	Zustandsklasse	[19], [20], [21]
Energieeffizienz von Produktionsmaschinen	Online-Optimierung des Energiezustands (gestoppt, stand-by, arbeitend) einer Produktionsmaschine zur Minimierung der Energiekosten sowie Lastspitzen	Bestärkendes Lernen (Deep-Q-Netzwerk (DQN), Proximal Policy Optimization (PPO), Memory Augmented Policy Optimization (MAPO))	Ist-Last und -Zustand der Maschine, Strompreis, Lastprofil, Last- und Verbrauchsgrenzen	Ziel-Last und -Zustand der Maschine	[22]
Optimierung Prozesssteuerung/ Störungserkennung	Erkennung von Zusammenhängen zwischen mehreren Prozessgrößen an einer SLM-Anlage	Auswahl geeigneter Anzahl an Clustern über die Elbow-Methode/ -Clustering mit k-Keans-Algorithmus	Log-(Sensor-) Daten der Maschinensteuerung	Geeignete Anzahl an Clustern für Clustering	[23]
Werkzeugverschleiß	Verschleißdetektion an Wendeschneidplatten	Zustandsklassifizierung mit Random Forest Classifier (weitere Klassifikatoren getestet)	Schallemission (MEMS-Sensor)	Verschleißklasse	[24]
Prozessüberwachung	Holistische Anlagen- und Prozessüberwachung bei subtraktiven Fertigungsverfahren	Semi-überwachtes Lernen, überwachtes Lernen	Körperschall	Anlagenzustände, Fehler, Verschleiß	[25], [26]
Prozessüberwachung	Identifikation kritischer Fertigungsparameter beim Bohren	Überwachtes Lernen	Zeit, Vorschub, Schnittgeschwindigkeit	Rauheit der Bohrung	[27]
NC-Bahnplanung	Fräsbearbeitung von Formwerkzeugen	Evolutionäre Algorithmen, Genetische Programmierung	Geometrie, Werkzeugdaten, Technologiedaten, ggf. vorhandene NC-Daten	optimierte (fünfsichtige) NC-Daten	[28], [29]
Prozessplanung und Design von Bohrungen	Anordnung und Prozessplanung für Kühlbohrungen in Formwerkzeugen	Evolutionsstrategie	Materialdaten, Werkzeug- und Prozessdaten, Kostendaten	Anordnung und Kostenabschätzung sowie Prozessparameter für Kühlbohrungen	[30]

Anwendungsdomäne	Anwendungsbeispiel	Realisierung mit ML	Eingangsgrößen	Ausgangsgröße	Ref.
<b>Handhabung/Montage/Robotik</b>					
Automatisiertes Greifen	Selbstoptimierung beim Griff in die Kiste	Deep-Learning, Transfer Learning	3D-Punktwolke	Bauteillage	[31], [32]
Qualitätskontrolle	Qualitätsvorhersage bei Oberflächenmontagetechnik in der Elektronikproduktion	Überwachtes Lernen (KNN, recurrent neural network (RNN), random forrest)	Prozessparameter	Transfereffizienz	[33]
Qualitätskontrolle	Anomaliedetektion bei mehrstufigen Montageprozessen	Unüberwachtes Lernen (u.a. k-Means-Algorithmus)	Prozessparameter	Anomalien wie Ausreißer, Sprünge oder Defekte	[34]
Qualitätskontrolle	Qualitätsvorhersage und Fehlerklassifikation beim Laserschweißen von Hairpins	Überwachtes Lernen (u. a. KNN, SVM, Convolutional Neural Networks (CNN))	Maschinenparameter, Bilddaten	Übergangswiderstand und Schweißfehler	[35], [36]
Qualitätskontrolle	Qualitätsvorhersage beim Ultraschallcrimpen im Elektromaschinenbau	Überwachtes Lernen (u.a. KNN, SVM, CNN)	Maschinenparameter, Bild- und Akustikdaten	Übergangswiderstand und Auszugskraft	[37], [38]
Qualitätskontrolle	Wicklungen in Nuten	CNN	Computertomographie-Schnittbild (CT-Schnittbild)	Validierung des Wickelprozesses	[39]
Qualitätskontrolle	Qualitätsprüfung mittels kamerabasierter Systeme	Robuste Detektion und Klassifikation (Faster R-CNN)	Bilddaten	Klassifikation & Detektion Qualitätsmerkmale	[40]
<b>Materialfluss/Logistik</b>					
Bauteilerkennung	Automatische Ersatzteil-erkennung im Turbinenbau (>50.000 Teile)	Deep Learning / Transfer Learning	Bilddaten des Bauteils aus 9 Kameraperspektiven	Identität des Bauteils	[41]
Ablaufsteuerung	Automatisches Erlernen von Speicher-programmierbaren-Steuerung-Programmen (SPS-Programmen) zur Materialflusssteuerung	Bestärkendes Lernen	Aktor-Sensordaten aus Hardware-in-the-Loop-Simulation	Steuerungsstrategie und Teile SPS-Programm	[42], [43]
Auftragsplanung	Adaptive Auftragsplanung in der Halbleiterindustrie	Bestärkendes Lernen	Auftragsdaten	Optimierter Auftragsablauf	[44], [45]
Auftragsplanung	Optimierung der Taktlinien in der synchronisierten Fertigung	Unüberwachtes Lernen (Clustering)	Auftragsdaten	Optimierte Taktlinien	[46]



Im Folgenden sollen einzelne Beispiele aus den verschiedenen Bereichen kurz erläutert werden.

## 6.1 CNC-Maschinen und -bearbeitung

Abbildung 6 zeigt das Prinzip einer Prozessüberwachung für die Fräsbearbeitung auf Basis eines KNN. Das Training des KNN erfolgt innerhalb der ersten Sekunden des Zerspanprozesses anhand der in der NC-Steuerung vorliegenden Prozessinformationen Achspositionen, -geschwindigkeiten und -ströme sowie weiterer hieraus abgeleiteter Größen. Anschließend ist das KNN in der Lage, die weiteren Prozesskräfte im Verlauf der Bearbeitung mit hoher Genauigkeit vorherzusagen. Diese Vorhersage dient als Referenz für die Überwachung der realen Zerspankräfte. [16], [17]

Diese KI-Anwendung zeigt beispielhaft die großen Nutzen- und Wertschöpfungspotenziale, die ML für die Simulation komplexer Fertigungsprozesse beinhaltet. Eine **klassische analytische Modellierung** wäre

hier aufgrund unbekannter Zerspankraftkoeffizienten nur mit erheblich **größerem Aufwand** möglich gewesen. In dem trainierten KNN wurden diese Parameter stattdessen implizit erlernt. **Expertenwissen aus der Produktion dient hierbei** der Auswahl aussagekräftiger Daten zum Training des Systems und der Bewertung der Güte bzw. Robustheit der Prozesssimulation.

Neben überwachten Lernverfahren bergen unüberwachte und semiüberwachte Verfahren gesonderte Potenziale zur Realisierung einer ganzheitlichen, interaktionsminimierten Anlagen- und Prozessüberwachung. Diese ermöglichen es, auch den in der industriellen Praxis meist größeren Anteil an vorhandenen Prozess- und Anlagendaten zur Generierung von Modellen zu nutzen, welcher nicht durchgehend Informationen über den tatsächlichen Anlagen- oder Prozesszustand bzw. die zu klassifizierende und prognostizierende Zielgröße beinhaltet. Hierdurch kann auf die teils äußerst aufwändige Generierung von umfassenden gelabelten Datensätzen und Etablierung dauerhafter Informationsschnittstellen, etwa zur speicherprogrammierbaren Steuerung (SPS), verzichtet

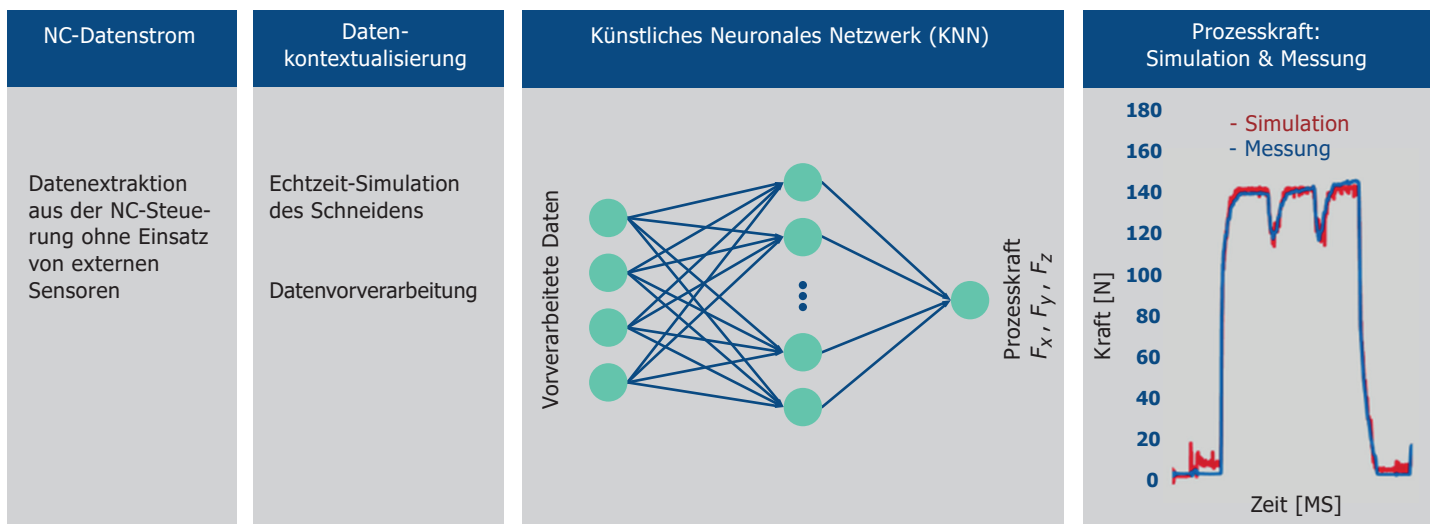


Abbildung 6: Prozessüberwachung durch simulierte Zerspankräfte auf Basis künstlicher neuronaler Netze

werden. Stattdessen können autarke, übertragbare Systeme realisiert werden, welche mit einem minimierten Informationsrückfluss durch den Anwender auskommen. Semi-überwachte Lernverfahren nutzen dabei den kleineren Anteil an gelabelten Daten, um eine initiale Schätzung der zugrundeliegenden Verteilung der Eingangsgrößen zu treffen, wodurch – kombiniert mit dem Großteil der ungelabelten Daten – eine höhere Vorhersageleistung erreicht werden kann. Hierbei können auch eigentlich unüberwachte Verfahren wie beispielsweise das hierarchische Clustering zur Nutzung eines semi-überwachten Lernprozesses erweitert werden [47]. Ferner können auch rein unüberwachte Verfahren in Kombination mit bestehendem a priori-Wissen genutzt werden, um eine Überwachung industrieller Prozesse zu realisieren [48].

Einen möglichen Anwendungsfall derartiger Systeme stellt die **Prozessüberwachung subtraktiver Fertigungsverfahren auf Basis des emittierten Körperschalls** dar. Die hohe Variantenvielfalt an Werkzeug-, Parameter- und Anlagenzuständen bedingt einen großen Zustandsraum für die auftretenden Signalsignaturen. Dies kann die Erstellung eines umfassenden und vollständig gelabelten Trainingsdatensatzes gegebenenfalls unrentabel machen. In der Nutzungsphase können dabei beispielsweise der zur Signalinterpretation notwendige aktive Betriebszustand der Maschine wiedererkannt und zeitgleich potenzielle Abweichungen vom Normverhalten (z. B. Rattern, Kollisionen) detektiert werden. Auch eine Verschleißquantifizierung der Werkzeuge durch eine nachgelagerte Signalanalyse ist möglich [25], [26] (siehe Abbildung 7).

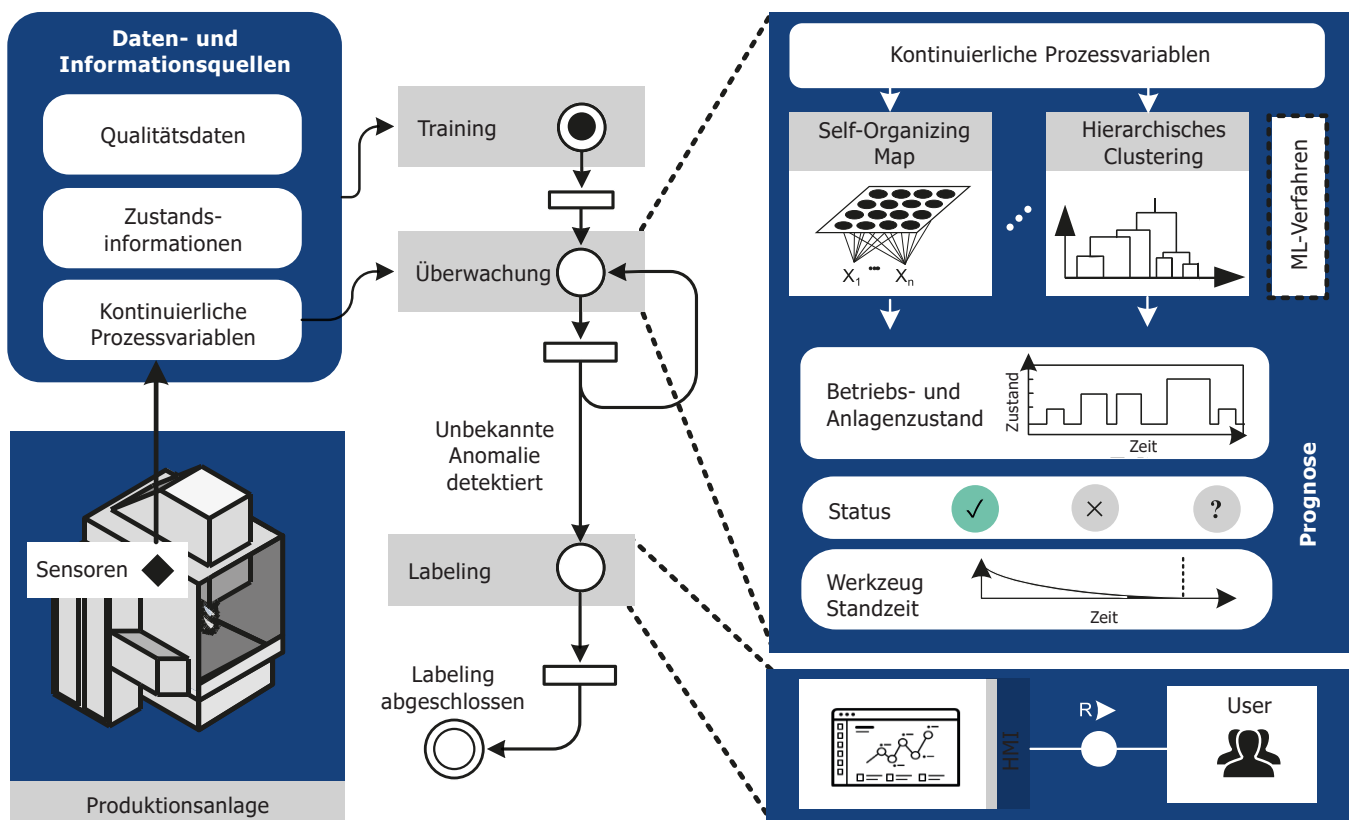




Abbildung 7: Ablauf und Architektur eines ML-basierten Prozessüberwachungssystems am Beispiel der spanenden Fertigung (in Anlehnung an [26])

## 6.2 Handhabung, Montage und Robotik

Das Potenzial einer Prozesssimulation zeigt sich im folgenden Beispiel auch in anderer Form. Hier werden basierend auf einer virtuellen Lernumgebung Handhabungsvorgänge beispielsweise für den industriellen „Griff in die Kiste“ [32] simuliert (Abbildung 8). Die im Rahmen einer Physiksimulation erzeugten gelabelten Daten bilden dann die Grundlage für das Training eines Prozessmodells, das auf einen realen Roboter übertragen wird. Um die in der Realität auftretenden Störeinflüsse in den Lerndaten abzubilden, werden in der Physiksimulation Rauschmodelle realer Systeme berücksichtigt.

Die hier gewählte Vorgehensweise zeigt das besondere **Potenzial des sogenannten Transfer Learnings** für produktionstechnische Anwendungen. Während der notwendige Umfang von Trainingsdaten wie im vorliegenden Fall des Robotergreifens in realen Prozessen oft nur über einen langen Zeitraum gewonnen werden kann, lassen sich simulierte Daten, wie in [31] beschrieben, auf der Basis produktionstechnischer Expertise und leistungsfähiger Rechnersysteme in kurzen Zeiträumen von wenigen Sekunden bis Stunden gewinnen. Im vorliegenden Beispiel fließt die **produktionstechnische Expertise insbesondere in die Bauteilvisualisierung, Simulation des Greifprozesses und Simulation von Störeinflüssen** ein.

Virtuelle Lernumgebung  
(z. B. Handhabungssimulation)



Transfer auf realen Roboter  
(mit ähnlichen Werkstücken)



Abbildung 8: Erlernen von Roboter-Greifvorgängen aus Handhabungssimulationen

### 6.3 Materialfluss und Logistik

Als Beispiel aus dem Anwendungsbereich Materialfluss und Logistik zeigt Abbildung 9 ein **kamerabasiertes Assistenzsystem zur Bauteil-identifikation** [41]. Die Besonderheit hierbei ist, dass aufgrund der hohen Anzahl unterschiedlicher zu identifizierender Bauteile – in diesem Anwendungsbeispiel ca. 1.000 von insgesamt 50.000 – pro Teil nur eine geringe Anzahl von Bilddaten für das Training gewonnen werden kann. Wie im vorangehenden Beispiel wird auch hier Transfer Learning erfolgreich eingesetzt. Dabei werden **durch Nutzung eines CNN** allgemein aussagekräftige Bildmerkmale zunächst über eine große Anzahl von Bilddaten nichtindustrieller Objekte erzeugt und diese Merkmale dann in der letzten Schicht des CNN mit den begrenzten Bilddaten der Ersatzteile verknüpft.

Durch diese **erstmalig auf industrielle Daten angewendete Form des Transfer Learning** konnten die Bilderkennungsraten gegenüber klassischen Bilderkennungsmethoden **um über 20 % gesteigert** werden [41].

In diesem Beispiel zeigt sich der Nutzen von produktionstechnischem Expertenwissen in besonderer Form. Aufgrund der kleinen Menge an Trainingsdaten hätte eine rein datengetriebene Betrachtung normalerweise zu dem Schluss geführt, dass die erzielbaren –Erkennungs-

quoten für die umfangreiche Menge an Bauteilen zu niedrig ausfallen werden, um den Prozess sinnvoll zu automatisieren. Bisher wurde die Teileidentifikation katalogbasiert manuell durchgeführt, wobei dieser Prozess zeitaufwändig und fehlerbehaftet war. Es **konnte jedoch ein Assistenzsystem entwickelt werden**, das unter Berücksichtigung der Detailkenntnis des Prozessablaufes und der auch auf kleinen Datenmengen erzielbaren absoluten Erkennungsraten in der Lage ist, mit einer Zuverlässigkeit von ca. 80 % die fünf wahrscheinlichsten Bauteile zu identifizieren und Referenzbilder dieser Teile aus einer Datenbank anzuzeigen. Der in dieser Form unterstützte Nutzer wählt schließlich das passende Bauteil aus. Durch diesen zweistufigen Prozess einer automatisierten Vorauswahl und darauf basierender menschlicher Entscheidungen konnte bei diesem, „LogicCube“ genannten Assistenzsystem eine signifikante Zeitersparnis bei gleichzeitiger Reduktion der Fehler gegenüber dem bisher rein manuellen katalogbasierten Verfahren erzielt werden.

Die Erfahrungen, die in den Forschungsarbeiten der WGP-Institute gewonnen wurden, können direkt innovativen industriellen Anwendungen in der Produktion zugutekommen. Zur Erstellung dieses Standpunktepapiers wurde daher analysiert, welche Erfahrungen mit den inzwischen umfangreichen Softwarewerkzeugen und ML-Frameworks, die heute überwiegend als Open Source verfügbar sind, gewonnen wurden. Ebenso wurde analysiert, welche spezifischen Kompetenzen der Produktionstechnik einerseits und des ML andererseits bei diesen Anwendungen erforderlich sind. Unter Berücksichtigung dieser Erfahrungen wurden die folgenden Handlungsempfehlungen formuliert.




Abbildung 9: Kamerasestütztes Assistenzsystem zur Identifikation von Bauteilen in der Ersatzteillogistik

## 7 Handlungsempfehlungen

Im vorliegenden Kapitel werden auf Grundlage der Erfahrungen der WGP Handlungsempfehlungen zur Implementierung von KI-Anwendungen in der Produktion geliefert. Hierbei werden sowohl operative Hinweise als auch strategische Perspektiven aufgeführt.

### 7.1 Analyse der unternehmenseigenen Zielsetzung

Zunächst muss das Unternehmen für sich die Frage klären, welche Form von „Intelligenz“ einer Maschine/Anlage/Roboter gewünscht wird (z. B. Erkennung des Maschinenzustands, Autonomie, automatische Adaption an Veränderungen wie Werkzeugverschleiß oder Bauteileigenschaften, selbständige Umplanung/ Selbstorganisation von Produktionsabläufen, Verstehen von menschlichen Befehlen oder Gesten zur vereinfachten Programmierung, Erkennen von Bauteilen) bzw. was eine Maschine selbständig lernen soll.

Wenn eine Maschine selbständig lernen soll, dann schließt sich die Frage an, **wer kontrolliert, ob etwas richtig gelernt wurde**, bevor die Maschine mit dem Wissen automatisch arbeitet. Das heißt auch, dass sich das Unternehmen überlegen muss, wann und auf welchen Daten eine Maschine lernt, bevor sie damit automatisiert arbeitet.

Jede dieser Zielsetzungen und Formen von „Intelligenz“ einer Maschine hat eine andere IT-Struktur als Basis und erfordert andere Herangehensweisen des ML.

Es ist auch zu analysieren, ob ML aus Sicht eines Unternehmens **Kernfunktionalität der Maschine oder Zusatzfunktionalität** sein soll. Dies entscheidet darüber, ob ein Unternehmen selbst Kernexpertise aufbauen oder die Technologieimplementierung durch einen Dritten vornehmen lassen sollte. Aufgrund der wachsenden Bedeutung des ML ist jedoch grundsätzlich zu empfehlen, auch im Unternehmen eine eigene Basisexpertise aufzubauen, die auch bei Maschinen mit einfachen Zusatzfunktionalitäten Anwendung findet.

### 7.2 Aufbau von Expertise

Beim Aufbau eigener Expertise im Unternehmen bietet es sich an, Aufgaben unter Anwendung von KI-Verfahren zunächst mit erfahrenen Dienstleistern oder Forschungseinrichtungen zu entwickeln. Hierbei kann im Unternehmen wertvolles, eigenes Erfahrungswissen aufgebaut werden – beispielsweise über einen kompletten Arbeitsablauf von der Analyse geeigneter Prozesse bezüglich ihrer Eignung für die Anwendung maschineller Lernverfahren über die Gewinnung und Vorbereitung der Daten bis hin zum Trainieren, Validieren und schließlich Testen des Modells.

Insbesondere in der Kooperation mit Forschungseinrichtungen bietet es sich an, gemischte Teams aus unternehmenseigenen Mitarbeitern und Institutsmitarbeitern gemeinsam Lösungen planen und integrieren zu lassen, um damit auch den notwendigen Wissenstransfer in das Unternehmen zu erhalten.

### 7.3 An einfachen Beispielen Erfahrungen sammeln

Hat das Unternehmen erste Erfahrungen aus Kooperationsprojekten gesammelt oder konnte es sich dank entsprechender qualifizierter Mitarbeiter Kompetenzen von außen holen, kann es beginnen, eigene Anwendungen aufzubauen. Hierbei ist zu unterscheiden, ob Softwarewerkzeuge der KI mit bereits fertigen Funktionalitäten in Prozesse oder Produkte integriert oder gezielt Fähigkeiten durch maschinelle Lernverfahren anhand unternehmenseigener Daten antrainiert werden sollen.

Im zweiten Fall helfen die mittlerweile in großer Anzahl verfügbaren Werkzeuge. Eine Übersicht hierzu gibt der „Quick Guide Machine Learning im Maschinen- und Anlagenbau“ des VDMA [7]. Es ist zu empfehlen, zum Aufbau von Erfahrungen im Unternehmen zunächst einfache Aufgabenstellungen zu verfolgen, beispielsweise Aufgaben der automatisierten Qualitätskontrolle mit Unterscheidung in Gut- bzw. Schlechteile (i. O. / n. i. O.), d. h. mit lediglich zwei automatisch zu unterscheidenden Klassen.

### 7.4 Produktionstechnisches Prozesswissen für ML identifizieren und nutzen

Im Rahmen der Forschungsarbeiten der WGP zur Nutzung von KI-Methoden in der Produktionstechnik zeigte sich durchweg der Nutzen produktionstechnischen Prozesswissens. Dieses ist **in vielen Unternehmen** in vielfältiger Weise vorhanden und bildet einen wesentlichen **Teil ihres Kapitals**. Der richtige Einsatz dieses Wissens ist mitentscheidend für die Geschwindigkeit und den Erfolg der Nutzung von KI-Methoden. Dazu wird empfohlen, sich die folgenden **zehn Kernpunkte aus den Erfahrungen der WGP-Forschung** bewusst zu machen und das Prozesswissen im Unternehmen gezielt in dieser Hinsicht zu untersuchen.

1. Prozesswissen ist entscheidend, um in der Produktion die richtigen Fragestellungen zu identifizieren und anzugehen. Nur so können die Kapazitäten richtig eingesetzt und sinnvoll genutzt werden.
2. Prozesswissen kann helfen, die Größenordnung der Problemstellung zu reduzieren, indem irrelevante Parameter von vornherein ausgeschlossen und bekannte Zusammenhänge von Parametern ausgenutzt werden. So kann der Bedarf an Daten reduziert und die Trainingsdauer verkürzt werden.



3. Prozesswissen kann helfen, die Datenlage mittels Augmentation zu verbessern. Hierbei werden Daten künstlich erzeugt oder vorhandene Datensätze um weitere Datenpunkte angereichert. Dabei wird der Prozess oder Datensatz auf geeignete Weise manipuliert oder sogar direkt auf Prozesssimulationen zurückgegriffen.
4. ML hat als Werkzeug kein Wissen über den Kontext, in dem es sich befindet. Dadurch kann es die eigenen Ergebnisse nicht interpretieren. Erst mit Prozesswissen wird eine Aussage darüber möglich, welche Güte ein System hat und wie das Ergebnis Einfluss auf den Prozess nehmen soll/kann/darf.
5. ML ist ein Werkzeug, welches statistische Fragestellungen beantwortet. Die Überführung von Fragestellungen der Anwender in entsprechende mathematische Formulierungen ist ohne Prozesswissen in Kombination mit Wissen über die Fähigkeiten von ML nicht möglich.
6. Die Akzeptanz maschineller Lernverfahren hängt wesentlich von dem Verhältnis ab, mit dem kritische Prozesszustände zuverlässig erkannt und Fehlalarme vermieden werden. Dieses Verhältnis wiederum hängt von der Parametrierung der Lernverfahren bzgl. deren Empfindlichkeit ab. Prozess- und Anwendungswissen ist daher notwendig, um die Empfindlichkeit des maschinellen Lernverfahrens optimal an die jeweilige Anwendung anpassen zu können.
7. Die Verfügbarkeit von annotierten (gelabelten) Daten ist ein maßgeblicher Faktor für den effizienten Einsatz von ML. Dabei fallen in Unternehmen bereits heute viele gelabelte Daten an, welche jedoch nicht maschinell erfasst werden. Im domänen-spezifischen produktionstechnischen Wissen über physikalische Zusammenhänge sind implizit die Verbindungen (Korrelationen und Kausalitäten) zwischen Daten und dem Prozessverhalten enthalten. Prozesswissen in Kombination mit Wissen über die Anforderungen von ML kann daher helfen, diese Datenquellen zu erkennen und Daten in geeigneter Form zur Verfügung zu stellen.
8. Relevante Größen sind nicht immer messbar. Prozesswissen erlaubt es teilweise, unter Ausnutzung bekannter Zusammenhänge die Größen indirekt zu erheben und für das ML verfügbar zu machen.
9. Hohe Datengüte stellt eine zwingende Voraussetzung für den Einsatz von ML dar. Moderne ML-Verfahren sind häufig bereits dafür geeignet, Ausreißer und Messrauschen in Daten implizit zu verarbeiten. Zum Teil kann die dabei gezielte Integration von atypischen

Daten auch helfen, die Generalisierungsfähigkeit der Erkennung von Prozessmustern zu verbessern. Auch hierzu kann Prozesswissen gezielt genutzt werden.

10. Bei der Anwendung maschineller Lernverfahren kann es hilfreich sein, die Aufgabenstellung in mehrere Schritte aufzuteilen, um die Leistung des Systems in einer hierarchischen Struktur zu verbessern. Hierbei kann beispielsweise Domänenwissen zur Verteilung von Daten und Produkt-, Prozess- oder Qualitätsparametern helfen, die Aufgabenstellung geeignet in Stufen zu unterteilen.

## 7.5 Daten systematisch gewinnen

Unabhängig davon, ob ein Unternehmen selbst Lösungen für sich entwickelt oder dieses durch einen Partner vornehmen lässt, sind die richtigen Daten zum Anlernen von KI-Methoden die wichtigste Grundlage. Bei der systematischen Gewinnung von Daten spielen die folgenden Schritte eine wesentliche Rolle:

- Identifikation von Datenquellen und darauf basierend weiterer Ausbau der „Sensorisierung“, beispielsweise in Form standardisierter Schnittstellen zwischen Maschinen und Anlagen
- Identifikation von Beziehungen zwischen Daten, die zum überwachten Lernen genutzt werden können
- Erfassung und Dokumentation der Beziehung zwischen den gewonnenen Daten und den Zuständen der Prozesse, aus denen diese gewonnen wurden
- Gezielter Einsatz von Simulationsverfahren zur Erweiterung der Datenbasis („Data Farming“)

## 7.6 Know-how gezielt zusammenführen

Ein Unternehmen, das Methoden des ML im Produktionsumfeld nutzen möchte, benötigt Experten, die eine verantwortliche Entscheidung über den Einsatz der Verfahren treffen können. Diese müssen jedoch entsprechend ausgebildet sein. Eine Herausforderung besteht darin, dass Absolventen aus einschlägigen Studiengängen mit KI-Bezug derzeit auch stark in Entwicklungsbereichen, z. B. der Softwareentwicklung nachgefragt sind. Um über den Einsatz von KI-Methoden in der Produktion entscheiden zu können, benötigt ein Unternehmen aber auch fundiertes produktionstechnisches Wissen. Nur dann lassen die Folgen von Fehlentscheidungen des antrainierten Systems abschätzen und das daraus entstehende Risiko für die Produktion bewerten. Experten, die beide Wissensbereiche vereinen, sozusagen „KI-Ingenieure“ werden derzeit jedoch auch universitär nicht gezielt ausgebildet. Maschinelle Lernverfahren lernen überwiegend statistische Verteilungen von Merkmalen. Hier entsteht ein fachlicher Bezug zu dem statistischen Grundlagen-

wissen, wie es in der Qualitätssicherung und dem Qualitätsmanagement benötigt wird, um produktionstechnische Prozesse bezüglich ihrer Qualität abzusichern. Eine Handlungsempfehlung besteht daher darin, **gemischte Teams einzurichten**, die zur Entscheidung über den Einsatz von maschinellen Lernverfahren die statistische Expertise zur Bewertung der Robustheit angelernter Systeme mit der Expertise zur produktionstechnischen Prozessabsicherung zusammenführen.

## 7.7 Potenziale vorausschauend bewerten

Die in Abbildung 2 dargestellte Entwicklung der Fortschritte in der Bilderkennung verläuft auch in anderen Anwendungsbereichen des ML in ähnlicher Form. Sie zeigt stellvertretend das aktuelle Potenzial des ML für die Automatisierung produktionstechnischer Prozesse. Hierauf basieren heutige Forschungs- und Entwicklungsarbeiten. Vor dem Hintergrund der zu beobachtenden Beschleunigung der Entwicklung des ML ist die Annahme, dass sich diese Fortschritte weiter fortsetzen, begründet. Das bedeutet jedoch, dass bereits heute Annahmen über die Leistungsfähigkeit maschineller Lernverfahren in fünf Jahren getroffen werden können. Bezogen auf Abbildung 2 könnte bei **Extrapolation der Entwicklungsfortschritte** der vergangenen zehn Jahre beispielsweise angenommen werden, dass in fünf Jahren die Restfehlerraten in der Bilderkennung von heute ca. 3 % auf dann ca. 0,5 % reduziert sein werden. Das würde bedeuten, dass ein mit ausreichend qualifizierten industriellen Bilddaten trainiertes Erkennungssystem dann annähernd fehlerfrei in der Lage sein wird, unterschiedliche Bauteile zu erkennen. Ein Roboter, der mit einer solchen Fähigkeit ausgestattet ist, wird damit mit einem deutlich höheren Grad an Flexibilität und Zuverlässigkeit Teile erkennen und greifen können. Dies eröffnet wiederum ganz neue Anwendungsbereiche für die Automatisierung von Handhabungsprozessen.

Große Unternehmen, die KI-Verfahren erfolgreich entwickeln und einsetzen, aber auch gezielt hierzu gegründete KI-Startups analysieren systematisch solche aus dem KI-Fortschritt vorhersehbaren Potenziale. Das Ziel ist, frühzeitig neue Wertschöpfungsmodelle zu identifizieren – beispielsweise für die Vermarktung von Produkten – und diese möglichst durch Patente zu schützen.

In der Produktion sind solche prospektiven **Szenarioanalysen** bisher jedoch nicht bekannt, obwohl in dieser Vorgehensweise auch hier ein klares Potenzial **zur Absicherung zukünftiger Wettbewerbsfähigkeit** von Unternehmen liegt. Es wird daher produzierenden Unternehmen wie auch Anlagenausüstern empfohlen, Kompetenzen und Expertise zur systematischen Nutzung dieser Potenziale aufzubauen.

## 7.8 KI-Methoden gezielt zur Assistenz einsetzen

Die Fortschritte auf dem Gebiet der KI-Methoden schüren die Erwartung, dass viele Maschinen, Anlagen und Prozesse zukünftig vollautomatisch gesteuert ablaufen können. Vor dem Hintergrund der heutigen hohen Anforderungen an Adaptivität und Flexibilität produktionstechnischer Prozesse werden jedoch auch bei technologisch hochentwickelten Produktionssystemen immer wieder die Grenzen vollautomatischer Abläufe sichtbar. Es wird daher auch zukünftig menschlicher Intelligenz bedürfen, um ein hohes Maß an Anpassungsfähigkeit und Flexibilität in der Produktion zu erreichen und zu sichern.

Um das **Potenzial der Verbindung menschlicher und maschineller Intelligenz auszuschöpfen**, wird daher empfohlen, gezielt zu analysieren, wo überlegene kognitive und sensomotorische Fähigkeiten des Menschen mit KI in der Produktion unterstützt werden können. Interessant ist dies insbesondere dort, wo menschliche Fähigkeiten mit Blick auf Ermüdung oder auch Aufnahmefähigkeit und Geschwindigkeit in der Verarbeitung von Informationen naturbedingt begrenzt sind.

Umgekehrt empfiehlt es sich bei den aktuell noch vorliegenden Grenzen maschineller Lernverfahren zu analysieren, inwiefern ggf. heutige Limitationen maschinell lernender Systeme durch die Fähigkeiten des Menschen ausgeglichen werden, also die limitierten Fähigkeiten der KI unterstützen Anlage durch den Menschen ergänzt werden können.

Bei solchen Analysen können methodische Vorgehensweisen wie die in Abbildung 4 dargestellte Verbindung von „tasks“ und „skills“ helfen. Allgemeinere methodische Modelle für die gezielte Identifikation und Entwicklung sinnvoller produktionstechnischer Assistenzfunktionen gilt es allerdings erst noch zu entwickeln. Im Sinne einer systematischen und effizienten Verbindung der unterschiedlichen Formen der Intelligenz von Mensch und Maschine in der Produktion sehen sich WGP-Institute in besonderer Weise gefordert.

## 8 Referenzen

- [1] Krüger, J.; Suwalski, I.: Fuzzy Logik und Neuronale Netze in der Maschinendiagnose. ZWF, 87 (1992) 11, S. 611-615
- [2] Specht, D.: Wissensbasierte Systeme im Produktionsbetrieb. München; Wien: Hanser, 1989
- [3] WGP e. V.: WGP-Standpunkt Industrie 4.0. Wissenschaftliche Gesellschaft für Produktionstechnik WGP e. V., Internet: [https://wgp.de/wp-content/uploads/WGP-Standpunkt\\_Industrie\\_4-0.pdf](https://wgp.de/wp-content/uploads/WGP-Standpunkt_Industrie_4-0.pdf), 2016
- [4] WGP e. V.: WGP-Standpunkt Industriearbeitsplatz 2025, Wissenschaftliche Gesellschaft für Produktionstechnik WGP e. V., <https://wgp.de/wp-content/uploads/WGP-.pdf>, 2018
- [5] Strategie Künstliche Intelligenz der Bundesregierung. November 2018. Internet: [www.ki-strategie-deutschland.de](http://www.ki-strategie-deutschland.de)
- [6] Chapman, P.; Clinton, J.; Kerber, R.; Khabaza, T.; Reinartz, T.; Shearer, C.; Wirth, R.: CRISP-DM 1.0 Step-by-step data mining guide. 2000
- [7] VDMA Software und Digitalisierung: Quick Guide Machine Learning im Maschinen- und Anlagenbau. VDMA, 2018. Internet: [sud.vdma.org](http://sud.vdma.org)
- [8] Seifert, I.; Bürger, M.; Wangler, L.; Christmann-Budian, S.; Rohde, M.; Gabriel, P.; Zinke, G.: Potenziale der künstlichen Intelligenz im produzierenden Gewerbe in Deutschland - Studie im Auftrag des Bundesministeriums für Wirtschaft und Energie (BMWi) im Rahmen der Begleitforschung zum Technologieprogramm PAiCE – Platforms | Additive Manufacturing | Imaging | Communication | Engineering. Hrsg.: iit-Institut für Innovation und Technik in der VDI / VDE Innovation + Technik GmbH, 2018.
- [9] Tremblay, J.; Prakash, A.; Acuna, D.; Brophy, M.; Jampani, V.; Anil, C.; To, T.; Cameracci, E.; Boochoon, S.; Birchfield, S.: „Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization,“ 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), Salt Lake City, UT, 2018, S. 1082–10828.
- [10] Agrawal, A.; Gans, J.; Goldfarb, A.: Prediction machines. Boston, Massachusetts: Harvard Business Review Press. 2018
- [11] Russakovsky, O.; Deng, J.; Su, H.; Krause, J.; Satheesh, S.; Ma, S.; Huang, Z.; Karpathy, A.; Khosla, A.; Bernstein, M.; Berg, A. C.; Fei-Fei, L.: ImageNet Large Scale Visual Recognition Challenge. IJCV, 2015
- [12] Brecher, C.; Eppe, A.; Fey, M.; Königs, M.; Neus, S.; Wellmann, F.: Lernende Produktionssysteme. In: Tagungsband zum AWK – Aachener Werkzeugmaschinen Kolloquium – Internet of Production für agile Unternehmen. Aachen, 18.-19. Mai 2017. Aachen: Apprimus, 2017, S. 135–161
- [13] Zwinkau, R.; Möhle, R.; Frentrup, S.; Deuse, J.: Metall/Nichtmetall-Klassifikation von Partikeln mit Deep Learning. JOT - Journal für Oberflächentechnik 58: S. 50–57, 2018
- [14] Wang, X., Eiseler, R., Moehring, H.-C.: Prediction and Optimization of Machining Results and Parameters in Drilling by using Bayesian Networks. Production Engineering, 2019 (in review)
- [15] Eigenbrod, H.; Hüttel, M.: Wenn jede Oberfläche anders ist: Selbstlernende Verfahren zur Prüfung von strukturierten Oberflächen Inspect: World of Vision. 17(5), 2016, S. 72-74
- [16] Königs, M.; Wellmann, F.; Wiesch, M.; Eppe, A.; Brecher, C.: A scalable, hybrid learning approach to process-parallel estimation of cutting forces in milling applications. In: Tagungsband zum 7. WGP-Jahreskongress. Aachen, 5.-6. Oktober 2017, S. 425-432
- [17] Brecher, C.; Wiesch, M.; Eppe, A.: Entwicklung eines Kraftschätzmodells beim Fräsen. Anwendung eines modernen, hybriden Lernansatzes auf Basis künstlicher neuronaler Netze zur prozessparallelen Ermittlung der Prozesskraft anhand maschineninterner Daten. In: ZWF – Zeitschrift für wirtschaftlichen Fabrikbetrieb. 112. Jg., November 2017, Nr. 11, S. 792–796
- [18] Burtscher, J.; Fleischer, J.: Adaptive tuned mass damper with variable mass for chatter avoidance. CIRP Annals, Volume 66, Issue 1, 2017, S. 397–400
- [19] Uhlmann, E.; Laghmouchi, A.; Geisert, C.; Hohwieler, E.: Smart wireless sensor network and configuration of algorithms for condition monitoring applications. Journal of Machine Engineering 17 (2017), No. 2, 2017, S. 45–55
- [20] Uhlmann, E.; Laghmouchi, A.; Ehrenpfordt, R.; Hohwieler, E.; Geisert, C.: Intelligentes Elektroniksystem für Condition Monitoring in Industrie 4.0: Mikro-elektromechanisches Elektroniksystem zur Zustands-, Verschleiß-, Prozess- und Anlagenüberwachung. ZWF, Vol. 111, No. 12, Hanser, 2016, S. 855–857
- [21] Laghmouchi, A.: Adaptives Entwicklungstool zur intelligenten Konfigurierung von Condition-Monitoring-Algorithmen. Stuttgart: Fraunhofer Verlag, 2017, zugl.: Berlin, TU, Diss., Berichte aus dem Produktionstechnischen Zentrum Berlin
- [22] Bakakeu J, Tolksdorf S, Bauer J, Klos H-H, Peschke J, Fehrl A et al. An Artificial Intelligence Approach for Online Optimization of Flexible Manufacturing Systems. AMM 2018;882: S. 96–108
- [23] Uhlmann, Eckart; Pastl Pontes, Rodrigo; Laghmouchi, Abdelhakim; Bergmann, André: Concept of sustainable data for a selective laser melting machine. Procedia manufacturing 21 (2018), S. 655–662
- [24] Verbundprojekt AMELI4.0: Mikro-elektromechanisches Elektroniksystem zur Zustandsüberwachung in der Industrie 4.0: Abschlussbericht zum Teilvorhaben AMELI4.0 – Data: Verschleiß-, Anlagen- sowie Prozessmonitoring durch intelligente, autonome Multi-Sensorsysteme. Berichter: Claudio Geisert. Projektleitung: Eckhard Hohwieler. Fraunhofer-Institut für Produktionsanlagen und Konstruktionstechnik. Zeitraum: 1. Dezember 2015 bis 30. November 2018. Förderkennzeichen BMBF 16ES0444
- [25] Kißkalt, D.; Fleischmann, H.; Kreitlein, S.; Knott, M.; Franke, J.: A novel approach for data-driven process and condition monitoring. Production Engineering. 12, 2018, S. 525–533

- [26] Kißkalt, D.; Mayr, A.; Lindenfels, J.; Franke, J.: Towards a Data-Driven Process Monitoring for Machining Operations Using the Example of Electric Drive Production. In: 2018 8th International Electric Drives Production Conference (EDPC). IEEE; 2018, S. 1–6
- [27] Mueller, T., Greipel, J., Weber, T., & Schmitt, R.: Automated root cause analysis of non-conformities with machine learning algorithms. *Journal of Machine Engineering*, 18, 2018, S. 60–72
- [28] Zabel, A.; Stautner, M.: Optimizing the Multi-Axis Milling Process via Evolutionary Algorithms. In: Proceedings of the 8th CIRP International Workshop on Modeling of Machining Operations, 2005, Chemnitz, Deutschland, S. 363–370
- [29] Weinert, K.; Mehnen, J.; Stautner, M.: The Application of Multi-objective Evolutionary Algorithms to the Generation of Optimized Tool Paths for Multi-Axis Die and Mould Making. In: Intelligent Computation in Manufacturing Engineering, 4th CIRP International Seminar on Intelligent Computation in Manufacturing Engineering, CIRP ICME ,04, 2004, Sorrento, Naples, Teti, R. (Hrsg.), S. 405–412
- [30] Biermann, D.; Joliet, R.; Michelitsch, T.; Wagner, T.: Sequential Parameter Optimization of an Evolution Strategy for the Design of Mold Temperature Control Systems. In: Proceedings of the 2010 IEEE Congress on Evolutionary Computation (IEEE CEC 2010), 18.7.-23.7. 2010, Barcelona, Spain, G. Fogel, H. Ishibuchi (Hrsg.)
- [31] Kleeberger, K.; Landgraf, C.; Huber, M. F.: Large-scale 6D Object Pose Estimation Dataset for Industrial Bin-Picking. To appear at 2019 IEEE/RISJ International Conference on Intelligent Robots and Systems (IROS), Macau, China, November 2019
- [32] Spenrath, F.; Pott, A.: Using Neural Networks for Heuristic Grasp Planning in Random Bin Picking. In: IEEE / Robotics and Automation Society: IEEE CASE 2018: 14th IEEE International Conference on Automation Science and Engineering. 20 to 24 August 2018, Munich, Germany. IEEE, 2018, S. 258–263
- [33] Seidel, A.; Mayr, A.; Schäfer, F.; Kißkalt, D.; Franke, J.: Towards a Smart Electronics Production Using Machine Learning Techniques. In: 42nd International Spring Seminar on Electronics Technology: Advances in Printed and Ceramic Microsystems, 2019, Wroclaw, Poland
- [34] Sand, C.; Kunz, S.; Hubbert, H.; Franke, J.: Towards an inline quick reaction system for actuator manufacturing using data mining. In: 2016 6th International Electric Drives Production Conference (EDPC). IEEE; 2016, S. 74–79
- [35] Mayr, A.; Lutz, B.; Weigelt, M.; Gläsel, T.; Seefried, J.; Kißkalt, D.; Franke, J.: Elektromotorenproduktion 4.0 – Potenziale des maschinellen Lernens in der Elektromotorenproduktion am Beispiel des Laserschweißens von Hairpins. *ZWF*, 2019;114(3):S. 145–149
- [36] Mayr, A.; Lutz, B.; Weigelt, M.; Gläsel, T.; Kißkalt, D.; Masuch, M. et al. Evaluation of Machine Learning for Quality Monitoring of Laser Welding Using the Example of the Contacting of Hairpin Windings. In: 2018 8th International Electric Drives Production Conference (EDPC). IEEE; 2018 - 2018, S. 1–7
- [37] Mayr, A.; Meyer, A.; Seefried, J.; Weigelt, M.; Lutz, B.; Sultani, D.; Hampl, M.; Franke, J.: Potentials of machine learning in electric drives production using the example of contacting processes and selective magnet assembly. In: 2017 7th International Electric Drives Production Conference (EDPC). IEEE; 2017 - 2017, S. 1–8
- [38] Weigelt, M.; Mayr, A.; Seefried, J.; Heisler, P.; Franke, J.: Conceptual design of an intelligent ultrasonic crimping process using machine learning algorithms. *Procedia Manufacturing* 2018;17:S. 78–85
- [39] Halwas, M.; Binder, D.; Fleischer, J.: Systematische Analyse des Lagenaufbaus von Wicklungen in Nuten elektrischer Maschinen mittels räumlicher Bildgebung und maschinellen Lernens, *www.umformtechnik.net*, 2018, S. 1–10
- [40] Frank D.; Chhor J.; Schmitt R.: Stereo-vision for autonomous industrial inspection robots, In 2017 IEEE International Conference on Robotics and Biomimetics (ROBIO), S. 2555–2561
- [41] Krüger, J., Lehr, J., Schlüter, M., Bischoff, N.: Deep learning for part identification based on inherent features. *CIRP Annals - Manufacturing Technology* 68, 2019
- [42] Jaensch, F., Csiszar, A., Scheifele, C., Verl, A.: Digital Twins of Manufacturing Systems as a Base for Machine Learning. In 2018 25th International Conference on Mechatronics and Machine Vision in Practice (M2VIP) (S. 1–6). IEEE
- [43] Jaensch, F., Csiszar, A., Kienzl, A., Verl, A.: Reinforcement Learning of Material Flow Control Logic Using Hardware-in-the-Loop Simulation. In 2018 First International Conference on Artificial Intelligence for Industries (AI4I) (S. 77–80). IEEE
- [44] Kuhnle, A.; Jakubik, J.; Lanza, G.: Reinforcement learning for opportunistic maintenance optimization, *Production Engineering*, Band 1, 2018, S. 33–41
- [45] Stricker, N.; Kuhnle, A.; Sturm, R.; Friess, S.: Reinforcement learning for adaptive order dispatching in the semiconductor industry, *CIRP Annals - Manufacturing Technology*, 2018, S. 511–514
- [46] Fels, A.; Ellerich, M.; Schmitt, R.: Cluster Analysis for enhancing process quality in job shop production. In: IRF2018. Proceedings of the 6th International Conference on Integrity-Reliability-Failure: S. 1413–1422
- [47] Chapelle, O., Scholkopf, B., Zien, A., Semi-supervised learning (Chapelle, O. et al., eds.; 2006) [book reviews]. *IEEE Transactions on Neural Networks*, 20(3), 2009, S. 542–542
- [48] Alhoniemi, E.; Hollmén, J.; Simula, O.; Vesanto, J.: Process Monitoring and Modeling Using the Self-Organizing Map. *Integrated Computer-Aided Engineering*, 6, 1999, S. 3–14

